

---

# Aplicación de Herramientas de Aprendizaje Reforzado y Aprendizaje Profundo en Simulaciones de Robótica de Enjambre con Restricciones Físicas

---

Marco Antonio Izeppi Rosales



UNIVERSIDAD DEL VALLE DE GUATEMALA  
Facultad de Ingeniería



**Aplicación de Herramientas de Aprendizaje Reforzado y  
Aprendizaje Profundo en Simulaciones de Robótica de  
Enjambre con Restricciones Físicas**

Trabajo de graduación presentado por Marco Antonio Izeppi Rosales  
para optar al grado académico de Licenciado en Ingeniería Mecatrónica

Guatemala,

2021

Vo.Bo.:

(f) \_\_\_\_\_  
Dr. Luis Alberto Rivera Estrada

Tribunal Examinador:

(f) \_\_\_\_\_  
Dr. Luis Alberto Rivera Estrada

(f) \_\_\_\_\_  
examinador No.1

(f) \_\_\_\_\_  
examinador No.2

Fecha de aprobación: Guatemala, 15 de diciembre de 2021.

---

## Prefacio

---

La idea del presente trabajo que lleva como título “Aplicación de Herramientas de Aprendizaje Reforzado y Aprendizaje Profundo en Simulaciones de Robótica de Enjambre con Restricciones Físicas” es establecer las bases para llegar a desarrollar proyectos cada vez más complicados dentro del entorno de robótica. Sentando las bases para futuras experimentaciones dentro de la Universidad del Valle de Guatemala.

Le agradezco a todos los miembros que conforman la comunidad universitaria los cuales me apoyaron para desarrollar este proyecto. Cada persona compartió un poco de su conocimiento sobre distintas áreas para lograr que este proyecto fuera posible. Mis más grandes agradecimientos al Dr. Luis Alberto Rivera por acompañarme a lo largo del desarrollo de esta tesis y a MSc. Miguel Zea por introducirme al mundo de la robótica. A mis compañeros que siempre estuvieron presentes para apoyarme y darme ánimos de seguir adelante y lograr alcanzar esta meta.

Finalmente, le agradezco a mi madre quien me brindo el privilegio de estudiar en la Universidad del Valle de Guatemala y a mi familia por siempre apoyarme en las decisiones que tome para llegar a este punto.

<b>Prefacio</b>	<b>III</b>
<b>Lista de figuras</b>	<b>VII</b>
<b>Lista de cuadros</b>	<b>VIII</b>
<b>Resumen</b>	<b>IX</b>
<b>Abstract</b>	<b>X</b>
<b>1. Introducción</b>	<b>1</b>
<b>2. Antecedentes</b>	<b>2</b>
2.0.1. Optimización de trayectorias de robots móviles en ambientes desconocidos . . . . .	2
2.0.2. Megaproyecto Robotat . . . . .	2
2.0.3. Algoritmo Modificado de Optimización de Enjambre de Partículas . . . . .	3
2.0.4. Algoritmo de optimización de enjambre y Artificial Potential Fields . . . . .	3
2.0.5. Algoritmo PSO modificado con aprendizaje reforzado y aprendizaje profundo . . . . .	4
<b>3. Justificación</b>	<b>5</b>
<b>4. Objetivos</b>	<b>6</b>
<b>5. Alcance</b>	<b>7</b>
<b>6. Marco teórico</b>	<b>8</b>
6.1. Optimización por Enjambres de Partículas (PSO) . . . . .	8
6.2. Aprendizaje Profundo . . . . .	9
6.3. Aprendizaje Reforzado . . . . .	10
6.3.1. Formulación del Aprendizaje Reforzado . . . . .	11
6.4. Algoritmo D* Lite para evasión de obstáculos . . . . .	12
6.5. Algoritmo de Dijkstra . . . . .	13

6.6.	Algoritmo de Braitenberg . . . . .	14
6.7.	Controlador PID . . . . .	15
6.8.	Regulador Cuadrático Lineal . . . . .	16
6.8.1.	Espacio de estados . . . . .	16
6.8.2.	Regulador cuadrático lineal (LQR) . . . . .	18
6.9.	Integrador cuadrático lineal (LQI) . . . . .	19
6.10.	Robot Diferencial E-Puck . . . . .	20
6.11.	Modelado de robots diferenciales . . . . .	21
6.12.	Funciones de costo . . . . .	22
6.12.1.	Función de esfera . . . . .	22
6.12.2.	Función de Rosenbrock . . . . .	23
6.12.3.	Función de Booth . . . . .	24
6.12.4.	Función de Himmelblau . . . . .	25
6.13.	Webots . . . . .	25
6.14.	Robot Operating System (ROS) . . . . .	26
6.15.	Gazebo . . . . .	27
6.16.	Rviz . . . . .	28
6.17.	Lenguaje de programación XML . . . . .	29
6.17.1.	Estructura de un documento XML . . . . .	29
6.17.2.	Partes de un documento XML . . . . .	29
<b>7.</b>	<b>Diseño experimental en Webots</b>	<b>31</b>
7.1.	Desarrollo de Algoritmo PSO . . . . .	31
7.2.	Algoritmo D* Lite para evasión de obstáculos . . . . .	33
7.3.	Algoritmo de Braitenberg . . . . .	34
7.4.	Selección de controladores . . . . .	36
<b>8.</b>	<b><i>Robotic Operating System (ROS)</i></b>	<b>37</b>
8.1.	Entorno de ROS . . . . .	37
8.1.1.	Comandos Básicos . . . . .	37
8.1.2.	Componentes Principales . . . . .	39
8.2.	Algoritmo de dijkstra . . . . .	40
<b>9.</b>	<b>Resultados</b>	<b>42</b>
9.1.	Simulación PSO sin obstáculos . . . . .	42
9.2.	simulación de algoritmo D* Lite . . . . .	45
9.3.	simulación de algoritmo Braitenberg y PSO . . . . .	46
<b>10.</b>	<b>Conclusiones</b>	<b>47</b>
<b>11.</b>	<b>Recomendaciones</b>	<b>48</b>
<b>12.</b>	<b>Bibliografía</b>	<b>49</b>
<b>13.</b>	<b>Anexos</b>	<b>52</b>
13.1.	Simulaciones de Webots sin obstáculos . . . . .	52
13.2.	Simulaciones con algoritmo D* lite . . . . .	59

---

## Lista de figuras

---

1.	Arquitectura de las redes neuronales [10]. . . . .	10
2.	Proceso de decisión de Markov [12]. . . . .	11
3.	Diagrama de braitenberg [17]. . . . .	15
4.	modelo del espacio de estados [20] . . . . .	17
5.	robot e-puck[23]. . . . .	20
6.	Localización del robot en el plano cartesiano [26]	21
7.	Comportamiento de la función de esfera [27]. . . . .	23
8.	Comportamiento de la función de Rosenbrock [27]. . . . .	24
9.	Comportamiento de la función de booth [27]. . . . .	24
10.	Comportamiento de la función de Himmelblau [27]. . . . .	25
11.	Logo de Webots [28]. . . . .	25
12.	Entorno de Gazebo . . . . .	28
13.	Entorno de Rviz . . . . .	28
14.	Representación gráfica del comportamiento del algoritmo PSO [37]	32
15.	Posición inicial y final del robot en el <i>Gridworld</i> . . . . .	33
16.	Trayectorias generadas por el algoritmo D* Lite . . . . .	34
17.	Sensores del robot e-puck [38] . . . . .	35
18.	Ejemplo de visualización de los nodos de ROS [39]. . . . .	38
19.	Ejemplo de la gráfica de conexiones entre los nodos [39]. . . . .	38
20.	Ejemplo de visualización de los temas activos en ROS [39]. . . . .	39
21.	espacio de búsqueda y la trayectoria generada por algoritmo de Dijkstra . . . . .	40
22.	Espacio de simulación de Gazebo en la posición inicial . . . . .	41
23.	Seguimiento de trayectoria de Dijkstra dentro del entorno de Gazebo . . . . .	41
24.	Trayectoria del robot utilizando un controlador PID . . . . .	43
25.	Trayectoria del robot utilizando un controlador LQR . . . . .	43
26.	Trayectoria del robot utilizando un controlador LQI . . . . .	44
27.	Trayectoria del robot utilizando el algoritmo D* Lite . . . . .	45
28.	Trayectoria de los robots utilizando el algoritmo de braitenberg y algoritmo PSO . . . . .	46
29.	Primer Conjunto de simulaciones dentro de Webots . . . . .	53

30.	Segundo Conjunto de simulaciones dentro de Webots . . . . .	54
31.	Tercer Conjunto de simulaciones dentro de Webots . . . . .	54
32.	Cuarto Conjunto de simulaciones dentro de Webots . . . . .	55
33.	Quinto Conjunto de simulaciones dentro de Webots . . . . .	55
34.	Sexto Conjunto de simulaciones dentro de Webots . . . . .	56
35.	Séptimo Conjunto de simulaciones dentro de Webots . . . . .	56
36.	Octavo Conjunto de simulaciones dentro de Webots . . . . .	57
37.	Noveno Conjunto de simulaciones dentro de Webots . . . . .	57
38.	Décimo Conjunto de simulaciones dentro de Webots . . . . .	58
39.	Primer conjunto de trayectorias generadas por el algoritmo D* Lite . . . . .	59
40.	Segundo conjunto de trayectorias generadas por el algoritmo D* Lite . . . . .	59
41.	Tercer conjunto de trayectorias generadas por el algoritmo D* Lite . . . . .	59

---

## Lista de cuadros

---

1.	efecto de las constantes en la salida del sistema [18]. . . . .	16
2.	características físicas del robot e-puck [25]. . . . .	20
3.	Promedio de tiempos de cada controlador por conjunto . . . . .	52

---

## Resumen

---

El algoritmo de optimización por enjambre de partículas (*Particle Swarm Optimization - PSO*) hace referencia a un método heurístico para resolver un tipo de problema computacional que evoca el comportamiento de las partículas en la naturaleza. En un principio fue concebido para elaborar modelos de conductas sociales, como el movimiento descrito por los organismos vivos en una bandada de aves, enjambres de insectos o un banco de peces. Posteriormente el algoritmo se simplificó y se comprobó que era adecuado para problemas de optimización utilizando partículas que simulan un ser individual dentro del enjambre.

Tomando esto en consideración, en las fases previas a este proyecto se desarrolló un algoritmo que utiliza métodos de Aprendizaje automático como lo es el aprendizaje profundo y el aprendizaje reforzado con la finalidad de crear un *Toolbox* en Matlab que optimice la selección de los parámetros que ingresan al sistema para mejorar la velocidad de convergencia de las partículas hacia el mínimo global.

En la siguiente tesis se describe implementación de este algoritmo, previamente diseñado, en un entorno de simulación con restricciones físicas, tomando en cuenta las dimensiones del robot y que es capaz de evadir obstáculos colocados dentro del entorno de simulación de forma aleatoria. Este algoritmo ya implementado en un sistema físico busca una rápida convergencia hacia el mínimo global al igual que evitar colisiones entre los robots o con los obstáculos. Por otro lado, se evalúa la viabilidad de la realización de simulaciones de sistemas multi-robot en el entorno de *Robotic Operating System* (ROS) debido a que es un *software* popular en el área de robótica, contiene diversas funcionalidades y presenta buenas simulaciones de condiciones físicas.

---

## Abstract

---

The Particle Swarm Optimization algorithm refers to a heuristic method for solving a type of computational problem that evokes the behavior of particles in nature. They were originally conceived to model social behavior, such as the movement described by living organisms in a flock of birds, swarms of insects, or a bank of fish. Later the algorithm was simplified and it was found to be suitable for optimization problems using particles that simulate an individual being within the swarm.

The PSO algorithm has several variants applied to various objectives such as multi-objective optimization, binary PSO, discrete PSO, combinatorial PSO, etc. Taking this into consideration, the Universidad del Valle de Guatemala began with a variant applied to mobile robots with the Robotat mega project, where the algorithm was part of the navigation system that differential robots would use to converge to a specific point.

Taking this into consideration, in the phases prior to this project, an algorithm was developed that uses machine learning methods such as deep learning and reinforced learning in order to create a Toolbox in Matlab that optimizes the selection of the input parameters of the system to improve the speed at which the particles converge towards the global minimum.

In this protocol, a graduation work is proposed that seeks an implementation of this algorithm, previously designed, in a simulation environment with physical restrictions, which takes into account the dimensions of the robot and is capable of avoiding obstacles placed within the simulation environment. . This algorithm already implemented in a physical system seeks a rapid convergence towards the global minimum as well as avoiding collisions between robots or with obstacles. On the other hand, it seeks to evaluate the feasibility of conducting simulations of multi-robot systems in the Robotic Operating System (ROS) environment because it is popular software in the robotics area and presents good simulations of physical conditions.

# CAPÍTULO 1

---

## Introducción

---

El algoritmo de Optimización por Enjambres de Partículas fue por primera vez introducido por Kennedy y Eberhart en su trabajo *Particle swarm optimization (PSO)* en 1995 [1]. Desde entonces, este algoritmo se ha utilizado en diversas ramas de la ingeniería, tales como la informática, civil, informática, etc. Este algoritmo se utiliza para resolver una gran cantidad de problemas relacionados con la optimización de funciones para encontrar mínimos y máximos, dependiendo de la aplicación.

En el caso de la Universidad del Valle de Guatemala, se empezó con el proyecto de Robotat en el cual se propuso la utilización del algoritmo de PSO como base para la navegación del conjunto de robots diferenciales. A partir de esto, se logró desarrollar un algoritmo capaz de tomar en cuenta las dimensión físicas de los robots diferenciales utilizados en el algoritmo PSO. Tomando este algoritmo como base, Eduardo Santizo [2] desarrolló un *Toolbox* capaz de calcular los hiper-parámetros del sistema para obtener un comportamiento deseable de los robots diferenciales y lograr su convergencia.

En el presente trabajo se busca la utilización del *Toolbox* diseñado por Eduardo Santizo para su implementación en simulaciones que no presenten condiciones ideales, tomando como parámetros base los valores dados por el *Swarm Robotics Toolbox* y *PSO Tuner*. También se tomo en consideración que el terreno que los robots exploran es un terreno desconocido con obstáculos colocados aleatoriamente dentro de el entorno. Las simulaciones de estos comportamientos se realizaran dentro de el entorno de Webots para tomar en consideración restricciones físicas tales como las dimensiones de los robots diferenciales, la gravedad, el rango de muestreo de los sensores, etc.

Se desea evaluar la viabilidad de la implementación del algoritmo PSO dentro del entorno de ROS ya que es un entorno que es ampliamente utilizado en la industria y posee diversas funcionalidades que nos permiten obtener mas información sobre el entorno y el funcionamiento del sistema. El entorno posee diversos programas para visualización, simulación, discretización de espacios, etc.

# CAPÍTULO 2

---

## Antecedentes

---

El algoritmo PSO posee diversas variantes aplicadas a diversos objetivos tales como optimización multiobjetivo, PSO binaria, PSO discreta, PSO combinatoria, etc. Tomando esto en consideración, dentro de la Universidad del valle de Guatemala se inició con una variante aplicada a robots móviles con el mega proyecto Robotat en donde el algoritmo formaba parte del sistema de navegación que utilizarían los robots diferenciales para converger a un punto específico [3].

### 2.0.1. Optimización de trayectorias de robots móviles en ambientes desconocidos

Safa Ziadi, Mohamed Njah y Mohamed Chtourou [4] utilizaron el enfoque de optimización de enjambre de partículas multiobjetivo (PSO) para optimizar los parámetros del Método Canónico de Campo de Fuerza. El cálculo de los parámetros óptimos se reinicia en cada nueva posición del robot y el PSO se utiliza para minimizar la distancia entre la posición y la meta a la cual se desea llegar y también para maximizar la distancia segura entre la posición actual del robot y los obstáculos cercanos. La eficacia del método se demuestra mediante simulaciones en el entorno de Webots. Las simulaciones se llevan a cabo en varios entornos conocidos y desconocidos. En los entornos conocidos, el robot reconoce la posición del obstáculo al comienzo de la navegación y la planificación de la ruta es global. Pero en los entornos desconocidos, la localización del robot se basa en las lecturas de los sensores y la planificación de la ruta es individual para cada robot, dependiendo de las lecturas de los sensores.

### 2.0.2. Megaproyecto Robotat

El Megaproyecto Robotat es un proyecto que tenía como objetivo el diseño de robots con aplicaciones de seguimiento de trayectorias y comportamientos de enjambre. A partir de esta idea se realizó el diseño electrónico y mecánico de los “Bitbots”. Inicialmente se enfocaron

en el diseño de *hardware* de los “Bitbots” y en un algoritmo de visión por computadora para obtener la posición y orientación de los robots en un plano bidimensional. Mas adelante, se empezaron a refinar detalles de *software* tales como el protocolo de comunicación y el algoritmo computacional que sería utilizado por los “Bitbots” [3]. Para el desarrollo del algoritmo de control para determinar el comportamiento de los robots se fueron desarrollando diversas tesis descritas a continuación:

### 2.0.3. Algoritmo Modificado de Optimización de Enjambre de Partículas

En [5] Aldo Aguilar buscó la implementación de un algoritmo modificado de optimización de enjambre de partículas con robots diferenciales reales. En el desarrollo de esta tesis se buscaba definir un algoritmo para establecer el comportamiento de los robots para que se asemeje al de un enjambre con capacidad de búsqueda de metas. Uno de los principales problemas que se presentó era el acople directo del movimiento de las partículas del PSO debido a que el movimiento era irregular generando la posibilidad de que se genere una saturación en los actuadores del robot.

Para solucionar este problema se planteó que cada robot no iría directamente a la posición calculada por el PSO, sino que se utilizaría la posición calculada por el PSO como una sugerencia del punto al cual debía desplazarse el robot. Durante este proceso se realizaron pruebas con ocho controladores diferentes, los cuales son: Transformación de uniciclo (TUC), Transformación de uniciclo con PID (TUCPID), Controlador simple de pose (SPC), Controlador de pose Lyapunov-estable (LSPC), Controlador de direccionamiento de lazo cerrado (CLSC), Transformación de uniciclo con LQR (TUC-LQR), y Transformación de uniciclo con LQI (TUC-LQI). Al finalizar las pruebas con estos ocho controladores se determinó que los mejores resultados en cuanto a la generación de trayectorias y velocidades continuas reguladas para los robots diferenciales era el controlador TUC-LQI y el TUC-LQR.

### 2.0.4. Algoritmo de optimización de enjambre y Artificial Potential Fields

En [6] Juan Cahueque realizó una implementación de la teoría de enjambre en el área de búsqueda y rescate de personas. Sabiendo que el movimiento de partículas bidimensional se realiza en una superficie tridimensional, siendo la tercera componente el resultado de la función de costo que nos indica cual es el mínimo global, podemos determinar hacia qué punto convergerán las partículas.

Juan Cahueque definió funciones artificiales de potencia de Choset y Kim, Wang y Shin con comportamiento multiplicativo y aditivo. Lo cual nos brinda la posibilidad de modelar una función de costo “personalizada” para establecer a qué punto convergerán las partículas. Se realizaron tres modelos, cada uno contaba con una meta y diversos obstáculos, los cuales tenían que evitar el robot para llegar a la meta.

Para lograr que estos modelos fueran implementables en robots diferenciales físicos, se emplearon los controladores propuestos por Aldo Aguilar [5] con algunas modificaciones para hacerlos compatibles con esta nueva metodología. Realizando diversas simulaciones se llegó a determinar los mejores parámetros para los controladores en los robots diferenciales

físicos. Cabe destacar que se tuvieron que realizar diversas pruebas con Webots, el cual es un *software* enfocado en simulaciones de robótica con restricciones físicas. Estas pruebas mostraron que los parámetros establecidos en Matlab eran idealizados y al ser implementados en Webots no brindaban el comportamiento esperado para el comportamiento del robot.

#### **2.0.5. Algoritmo PSO modificado con aprendizaje reforzado y aprendizaje profundo**

En [2] Eduardo Santizo empleó la metodología de aprendizaje reforzado y aprendizaje profundo para desarrollar un *PSO tuner* y un generador de trayectorias. Para el desarrollo del *PSO tuner*, se empleo una red neuronal recurrente que toma diversas métricas propias de las partículas PSO y realiza una predicción de los valores óptimos para los parámetros relevantes del algoritmo. Entrenando las redes neuronales con 7,700 simulaciones de un algoritmo estándar de PSO se generan predicciones de carácter dinámico, logrando que el algoritmo final redujera el tiempo de convergencia y susceptibilidad a mínimos locales del PSO original.

Para el generador de trayectorias se utilizó aprendizaje profundo. En las pruebas iniciales se utilizó una cuadrícula simulando el *gridworld* de Webots en el cual el robot solo tenía la posibilidad de moverse en 4 direcciones: arriba, abajo, izquierda o derecha. Al robot se le daban penalizaciones si colisionaba contra un obstáculo y se le daba un premio si era capaz de esquivar el obstáculo. Si el robot llegaba a la meta rápidamente recibía un premio aún mayor. Usando este sistema de premios y penalizaciones, se entrenó al algoritmo para predecir de mejor manera la trayectoria. Luego se modificó el algoritmo para permitir el movimiento en diagonales a 45°, Por lo que se tienen ocho posibles movimientos y se siguió la misma metodología anteriormente descrita. Cabe destacar que la propuesta de Eduardo Santizo se enfocaba directamente en los algoritmos de aprendizaje reforzado y aprendizaje profundo por lo cual no se llegaron a realizar simulaciones con restricciones físicas.

# CAPÍTULO 3

---

## Justificación

---

El algoritmo de PSO nos permite optimizar un problema (función de costo) a partir de una población de soluciones candidatas o “partículas” que se mueven por todo el espacio de búsqueda según diversas reglas matemáticas que tienen en cuenta la posición y la velocidad en ese instante de las partículas. El movimiento de cada partícula se ve influido por la mejor posición que ha encontrado hasta el momento, así como por las mejores posiciones globales encontradas por las demás partículas a medida que recorren el espacio de búsqueda.

En la fase previa, se desarrolló un algoritmo que se “adapta” a la función de costo para obtener los parámetros óptimos y brindar un mejor comportamiento de las partículas para lograr una convergencia rápida y efectiva hacia el mínimo o máximo del a función. Sin embargo, no se han realizado pruebas en entornos físicos tomando en consideración los controladores a utilizar y la validación del comportamiento esperado por parte de los robots con condiciones físicas.

Debido a esto, en este proyecto buscó la integración de simuladores de condiciones físicas junto con el algoritmo adaptado con aprendizaje profundo y aprendizaje reforzado para la optimización de funciones de costo para la obtención de los parámetros óptimos en un entorno estático. Se verificaron y validaron los resultados obtenidos en entornos físicos simulados con restricciones físicas, con los resultados obtenidos a partir de simulaciones ideales del comportamiento de los robots. Esto estableció las bases para futuras experimentaciones que resuelvan cada vez problemas más complejos brindando resultados satisfactorios.

Se evaluó la viabilidad de la simulación de dicho algoritmo en el entorno de ROS debido a que es un *software* popular en el área de robótica por sus buenas simulaciones de condiciones físicas como lo son la fricción, la interacción de las fuerzas, etc. Además, cuenta con diversos modelos de robots, actuadores y sensores los cuales son actualizados por las mismas empresas o algunos diseñadores para brindar un simulador muy completo.

Por lo tanto, se puede considerar a el entorno de ROS como un *software* de gran utilidad para la evaluación del comportamiento de robots en condiciones físicas y definir controladores apropiados que nos brinden el comportamiento esperado.

# CAPÍTULO 4

---

## Objetivos

---

### Objetivo General

Integrar las herramientas de *software PSO Tuner* y *Swarm Robotics Toolbox*, desarrolladas en la fase anterior, a plataformas de simulación con restricciones físicas.

### Objetivos Específicos

- Evaluar entornos de simulación con motores de física que permitan simulaciones de robótica de enjambre más realistas.
- Realizar simulaciones en el entorno seleccionado y obtener datos de entrenamiento para el *PSO Tuner* y *Swarm Robotics Toolbox*.
- Utilizar los parámetros obtenidos por el *PSO Tuner* y el *Swarm Robotics Toolbox*, luego del entrenamiento, en nuevos escenarios, y verificar el rendimiento del sistema.
- Evaluar la viabilidad del uso de ROS para aplicaciones de robótica de enjambre en combinación con las herramientas *PSO Tuner* y *Swarm Robotics Toolbox*.

## CAPÍTULO 5

---

### Alcance

---

Este proyecto tiene como propósito implementar el algoritmo PSO para robots diferenciales en entornos con restricciones físicas. Se busca lograr que el sistema sea capaz de evadir obstáculos en entornos desconocidos siendo capaz de lograr converger al punto mínimo del sistema planteado, tomando en consideración restricciones físicas tales como la gravedad, las dimensiones del sistema, etc.

Por otro lado, se busca la implementación del algoritmo dentro del entorno de *Robotic Operating System* (ROS) debido a que es un entorno de simulación creado para simular condiciones físicas que se asemejen a una implementación real dentro de cualquier entorno desconocido. El algoritmo debe de ser capaz de simular comportamientos similares a una implementación física real.

El motivo de esta investigación es lograr determinar un correcto funcionamiento del sistema en condiciones no ideales. El sistema debe ser capaz de lograr converger al mínimo global del sistema. Por otro lado, se desea lograr crear ejemplos de implementaciones dentro del sistema de ROS para futuras implementaciones dentro del sistema en cursos universitarios.

Estas simulaciones buscan un sistema capaz de converger al mínimo global tomando en consideración que existen obstáculos dentro del entorno. Deben ser capaces de poder evadir dichos obstáculos de forma segura evitando cualquier tipo de contacto entre el robot diferencial y el obstáculo colocado aleatoriamente dentro del entorno.

# CAPÍTULO 6

---

## Marco teórico

---

### 6.1. Optimización por Enjambres de Partículas (PSO)

La Optimización por Enjambres de Partículas (conocida como PSO, por sus siglas en inglés, Particle Swarm Optimization) es una técnica de optimización/búsqueda. Este método fue descrito alrededor de 1995 por James Kennedy y Russell C. Eberhart [1], y se inspira en el comportamiento de los enjambres de insectos en la naturaleza. Formalmente hablando, se supone que tenemos una función desconocida,  $f(x, y)$ , que podemos evaluar en los puntos que queramos, pero a modo de caja negra, por lo que no podemos conocer su expresión. El PSO es fácil de implementar y ha sido ampliamente usado en variadas aplicaciones con resultados excelentes resolviendo problemas reales de optimización. Este algoritmo puede ser computacionalmente ineficiente por que puede quedar atrapado fácilmente en óptimos locales cuando resuelve problemas cuyo espacio de solución es multimodal; estas debilidades han hecho que el campo de aplicación de la metodología esté un poco restringido [7].

El objetivo es el habitual en optimización, encontrar valores de  $x$  y  $y$  para los que la función  $f(x, y)$  sea máxima (o mínima, o bien verifica alguna relación extremal respecto a alguna otra función). La idea que vamos a seguir en PSO comienza de forma similar, situando partículas al azar en el espacio de búsqueda, pero dándoles la posibilidad de que se muevan a través de él de acuerdo con unas reglas que tienen en cuenta el conocimiento personal de cada partícula y el conocimiento global del enjambre [7].

Cada partícula (individuo) tiene una posición,  $p$  (que en 2 dimensiones vendrá determinado por un vector de la forma  $[x, y]$ ), en el espacio de búsqueda y una velocidad,  $v$  (que en 2 dimensiones vendrá determinado por un vector de la forma  $[v_x, v_y]$ ), que determina su movimiento a través del espacio. Además, como partículas de un mundo real físico, tienen una cantidad de inercia, que los mantiene en la misma dirección en la que se movían, así como una aceleración (cambio de velocidad), que depende principalmente de dos características:

- Cada partícula es atraída hacia la mejor localización que ella, personalmente, ha encontrado en su historia (mejor personal).

- Cada partícula es atraída hacia la mejor localización que ha sido encontrada por el conjunto de partículas en el espacio de búsqueda (mejor global).

Formalmente, lo podemos escribir como:

$$v_i(t+1) = v_i(t) + C_1 r_1(p_i^{mejor} - p_i(t)) + c_2 r_2(p_g^{mejor} - p_i(t)) \quad (1)$$

En donde:

- $c_1, c_2$  = son las constantes de atracción al mejor personal y el mejor global
- $r_1, r_2$  = son números aleatorios entre 0 y 1
- $p_i^{mejor}$  = es la mejor posición por la cual ha pasado una partícula
- $p_g^{mejor}$  = es la mejor posición global de todo el sistema de enjambre

Una vez actualizadas las velocidades de todas las partículas, sus posiciones se actualizan siguiendo una ley simple:

$$p_i(t+1) = v_i(t) + p_i(t) \quad (2)$$

un conjunto de partículas representa potenciales soluciones, donde cada partícula  $i$  está asociada a dos vectores, el vector de velocidades y a la posición del vector. La velocidad y la posición de cada partícula son inicializadas por vectores aleatorios con sus correspondientes rangos [8].

## 6.2. Aprendizaje Profundo

En el enfoque Aprendizaje Profundo se usan estructuras lógicas que se asemejan en mayor medida a la organización del sistema nervioso de los mamíferos, teniendo capas de unidades de proceso (neuronas artificiales) que se especializan en detectar determinadas características existentes en los objetos percibidos. La visión artificial es una de las áreas donde el Aprendizaje Profundo proporciona una mejora considerable en comparación con algoritmos más tradicionales. Existen varios entornos y bibliotecas de código de Aprendizaje Profundo que se ejecutan en las potentes GPUs modernas tipo CUDA, como por ejemplo NVIDIA cuDNN.

El Aprendizaje Profundo representa un acercamiento más íntimo al modo de funcionamiento del sistema nervioso humano. Los modelos computacionales de Aprendizaje Profundo imitan estas características arquitecturales del sistema nervioso, permitiendo que dentro del sistema global haya redes de unidades de proceso que se especialicen en la detección de determinadas características ocultas en los datos. El Aprendizaje Profundo lleva a cabo el proceso de *Machine Learning* usando una red neuronal artificial que se compone de un número de niveles jerárquicos. En el nivel inicial de la jerarquía la red aprende algo simple y luego envía esta información al siguiente nivel. El siguiente nivel toma esta información sencilla, la combina, compone una información algo un poco más compleja, y se lo pasa al

tercer nivel, y así sucesivamente. Destaca porque no requiere de reglas programadas previamente, sino que el propio sistema es capaz de “aprender” por sí mismo para efectuar una tarea a través de una fase previa de entrenamiento [9].

Los algoritmos que componen un sistema de aprendizaje profundo se encuentran en diferentes capas neuronales compuestas por pesos (números). El sistema está dividido principalmente en 3 capas:

- **Capa de entrada (Input Layer):** Está compuesto por las neuronas que asimilan los datos de entrada, como por ejemplo imagen o una tabla de datos.
- **Capa oculta (Hidden Layer):** Es la red que realiza el procesamiento de información y hacen los cálculos intermedios. Cada más neuronas en esta capa haya, más complejos son los cálculos que se efectúan.
- **Salida (Output Layer):** Es el último eslabón de la cadena, y es la red que toma la decisión o realiza alguna conclusión aportando datos de salida.

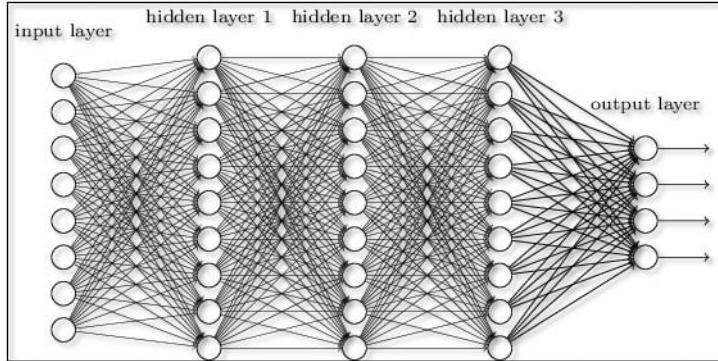


Figura 1: Arquitectura de las redes neuronales [10].

### 6.3. Aprendizaje Reforzado

El Aprendizaje por refuerzo es un área del aprendizaje automático inspirada en la psicología conductista, cuya ocupación es determinar qué acciones debe escoger un agente de software en un entorno dado con el fin de maximizar alguna noción de “recompensa” o premio acumulado. Intenta conseguir que una inteligencia artificial aprenda a decidir mediante su propia experiencia. Es decir, que ante una situación determinada, sea capaz de seleccionar por sí misma la mejor acción a ejecutar en ese momento mediante un proceso interactivo de prueba y error a base de reforzar positivamente cada vez que se aproxima o logra objetivo. Por eso, con el Aprendizaje reforzado una máquina puede tomar decisiones aunque no almacene un conocimiento a priori del entorno o de las variables que se están dando, y realizar de manera satisfactoria cuestiones abstractas más avanzadas. [11]

La aplicación de ese aprendizaje les permite ya reconocer caras, clasificar secuencias de ADN, conducir vehículos, o hacer diagnósticos médicos. En la actualidad compañías tecnológicas punteras como Google, Apple o IBM, están invirtiendo en investigación para entrenar

robots que realicen sencillas tareas mediante esta técnica. El aprendizaje por refuerzo es especialmente adecuado para los problemas que incluyen un razonamiento a largo plazo frente a uno a corto plazo. Se ha aplicado con éxito a diversos problemas, entre ellos el control de robots, telecomunicaciones, backgammon y damas. [11]

Dos componentes hacen aprendizaje por refuerzo de gran alcance: el uso de muestras para optimizar el rendimiento y el uso de la función de aproximación para hacer frente a entornos de gran tamaño. El problema de aprendizaje reforzado requiere mecanismos de exploración inteligente. Seleccionar al azar acciones, sin hacer referencia a una distribución de probabilidad estimada, que se conoce para dar lugar a un rendimiento muy pobre. [11]

### 6.3.1. Formulación del Aprendizaje Reforzado

El Aprendizaje Reforzado se plantea como una herramienta de resolución de problemas de toma de decisiones secuenciales, del cual se supone clásicamente que se rige mediante un proceso de decisión de Markov. En este caso, el proceso queda conformado por los elementos presentes en la Figura 2, y puede describirse mediante la tupla  $MDP = (S, A, R, P)$  [12]. Adicionalmente, la propiedad de Markov en este caso queda descrita como se presenta en la ecuación 3.

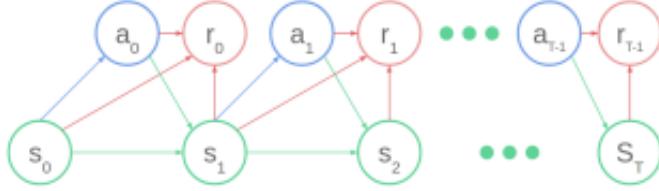


Figura 2: Proceso de decisión de Markov [12].

$$\forall t \quad P(s_t | s_{t-1}, a_{t-1}) = P(s_t | s_{t-1}, \dots, s_0, a_{t-1}, \dots, a_0) \quad (3)$$

De la Figura 2,  $S$  y  $A$  representan al espacio de estados y acciones respectivamente. La formulación general no tiene restricciones con respecto a la naturaleza de dichos espacios, pero los trabajos clásicos y las principales garantías de convergencia existen solo para el caso de espacios discretos, en donde no existe necesidad de utilizar aproximadores funcionales. Por otro lado,  $R$  representa a la recompensa escalar, pilar fundamental del Aprendizaje Reforzado. Existen diferentes definiciones de la misma, ya sea  $R : S \rightarrow R$ ,  $R : S \times A \rightarrow R$  o incluso  $R : S \times A \times S \rightarrow R$ . Finalmente  $P$  representa a la función de transición, que usualmente es considerada estocástica, es decir:  $P : S \times A \times S \rightarrow [0, 1]$ . Una de las ventajas del Aprendizaje Reforzado con respecto a otras metodologías como el control óptimo, es que precisamente no se asume  $P$  como conocida (y muchos casos nunca se aprende directamente) [12].

Finalmente, el producto del proceso de aprendizaje, el cuál es además el objeto matemático que directa o indirectamente se modifica durante el entrenamiento corresponde a la política  $\pi$ . La política corresponde a un mapeo entre el espacio de estados y el espacio de

acciones, el cual puede ser determinista  $\pi : S \rightarrow A$  o estocástico  $\pi : S \times A \rightarrow [0, 1]$ . En la literatura se suele recomendar la utilización de políticas estocásticas en aquellos problemas en los que se presente observabilidad parcial. Sin embargo estudios recientes, algoritmos que aprenden políticas determinísticas han sido capaces de abordar problemas complejos con observabilidad parcial [13].

## 6.4. Algoritmo D\* Lite para evasión de obstáculos

El algoritmo D\* Lite es un algoritmo de búsqueda que resuelve los mismos problemas de planificación de ruta basada en la suposición, incluyendo la planificación con la suposición de espacio libre, donde un robot tiene que navegar hasta las coordenadas de un objetivo dado en un terreno desconocido. Hace suposiciones sobre la parte desconocida del terreno y encuentra un camino más corto desde sus coordenadas actuales hasta la meta bajo estas suposiciones. El robot entonces sigue el camino. Cuando se observa nueva información del mapa, se añade la información a su mapa y, si es necesario, planea el nuevo camino más corto a partir de sus coordenadas actuales a las coordenadas del objetivo determinado. Se repite el proceso hasta que llega a las coordenadas del objetivo o determina que no se puede llegar a las coordenadas del objetivo [14].

El algoritmo se basa en LPA\* (*Lifelong Planning A\**) el cual es una versión incremental del algoritmo A\*. Este algoritmo se aplica a un espacio finito problemas de búsqueda en espacios conocidos cuyos costos aumentan o disminuyen con el tiempo.  $S$  denota el numero finito de vértices en el espacio.  $Succ(s) \subseteq S$  denota el numero de sucesores del vértice  $s \in S$  y  $Pred(s) \subseteq S$  denota el numero de predecesores del vértice  $s \in S$ . El algoritmo LPA\* siempre determina el camino mas corto desde un vértice inicial  $s_{inicial} \in S$  a el vértice final  $s_{meta} \in S$ . La función  $g*(s)$  denota la distancia mas corta entre el vértice inicial y el vértice final. Al igual que A\*, el algoritmo LPA\* utiliza la heurística para aproximar la distancia desde cada vértice hasta el vértice final [14].

El algoritmo LPA\* mantiene una estimación  $g(s)$  de la distancia inicial y una estimación  $g*(s)$  para cada vértice dentro del espacio. También mantiene un segundo tipo de valor estimado de la distancias iniciales. Estos valores corresponden a  $rhs(s)$  el cual es un valor adelante del valor de  $g(s)$  y corresponde a lo siguiente:

$$rhs(s) = \begin{cases} 0, & \text{if } s = s_{inicial} \\ \min_{s' \in Pred(s)} (g(s') + c(s', s)), & \text{otherwise} \end{cases} \quad (4)$$

Si el valor de  $rhs(s)$  es igual al valor de  $g(s)$  entonces el vértice es localmente consistente, sin embargo, si el valor de  $rhs(s)$  es diferente de  $g(s)$  el vértice es localmente inconsistente. Si todos los vértices son localmente consistentes, entonces los valores de  $g(s)$  son iguales a sus distancias iniciales. En este caso, se puede calcular el camino mas corto desde el vértice  $s_{inicial}$  a cualquier vértice que sea predecesor ( $s'$ ) que minimice  $g(s') + c(s', s)$  hasta que se llegue hasta el vértice final [14].

En el caso de que existan vértices que sean localmente inconsistentes se utiliza la heurística para centrar la búsqueda y actualizar los valores de  $g(s)$  que son relevantes para encontrar el camino mas corto. Para realizar esto, el algoritmo utiliza una cola de prioridad,

la cual solo contiene los vértices que son localmente inconsistentes. La prioridad de un vértice se determina utilizando un vector con dos componentes:  $k(s) = [k_1(s); k_2(s)]$ , en donde  $k_1(s) = \min(g(s), rhs(s)) + h(s, s_{meta})$  y  $k_2(s) = \min(g(s), rhs(s))$ . El algoritmo LPA\* siempre expande el vértice en la cola de prioridad que contiene los valores más pequeños [14].

Hasta ahora, hemos descrito el funcionamiento del algoritmo LPA\*, el cual calcula siempre el camino más corto entre el vértice inicial y el vértice final conforme el costo de cada vértice va cambiando. Se procede a explicar el algoritmo D\* lite utilizando este algoritmo como base. Con el algoritmo D\* lite se puede determinar el camino más corto tomando en consideración el cambio del costo de cada vértice a medida que el robot se va moviendo desde el vértice inicial hacia el vértice final. Para esto, se realizan solo dos cambios al algoritmo LPA\* los cuales son:

- Se cambia la dirección de la búsqueda ya que el algoritmo LPA\* busca el camino más corto desde la posición  $s_{meta}$  hasta  $s_{inicio}$ . Debido a que se quiere actualizar los nodos tomando en consideración la posición actual del robot, es necesario invertir la forma en la cual se calcula el camino más corto generando que se calcule desde  $s_{inicio}$  hasta  $s_{meta}$  [14].
- se introduce un modificador a la cola de prioridad para tomar en consideración cuando el robot se mueve desde  $s_{inicio}$  a  $s'_{inicio}$ . Este modificador causa que al momento de agregar de nuevo los nodos a la cola de prioridad incremente el valor de los nodos más alejados y evite tomar en consideración los nodos predecesores como vértices a los cuales se puede mover [14].

Finalmente, nuestra nueva función para la cola de prioridad quedaría de la siguiente forma:

$$k(s) = [\min(g(s), rhs(s)) + h(s, s_{meta}) + k_m; \min(g(s), rhs(s))] \quad (5)$$

En donde:

$$k_m = k_m + h(s, s') \quad (6)$$

## 6.5. Algoritmo de Dijkstra

El algoritmo de Dijkstra fue creado y publicado por el Dr. Edsger W. Dijkstra, un ingeniero en sistemas y ciencias de la computación. El algoritmo de Dijkstra permite encontrar el camino más corto entre dos vértices de un grafo. Para describir el algoritmo partimos de la definición de un grafo, como la representación gráfica de un conjunto de nodos o vértices unidos por enlaces llamados aristas o arcos [15]. Existen dos tipos de grafos:

- **Indirectos:** Por cada par de nodos en el grafo, se puede ir de un nodo a otro en ambas direcciones.
- **Directos:** Por cada par de nodos en el grafo, solo se puede ir de un nodo a otro en una dirección específica.

El algoritmo de Dijkstra utiliza grafos ponderados. Un grafo ponderado es un grafo cuyos vértices tienen un peso o costo. El peso o costo de estos vértices puede representar tiempo, distancia o cualquier tipo de dato que modele una conexión entre los pares de nodos [15].

Asumiendo que se tiene un grafo  $G = (V, E)$  como un conjunto de vértices  $V$  donde  $V = [v_0, v_1, \dots, v_{n-1}]$  y un conjunto de aristas  $E$  que unen los vértices, a los cuales se les asocia un peso. El orden de complejidad del algoritmo de Dijkstra es de  $O(n^2)$  [16]. A continuación se describe el pseudocódigo del algoritmo en los siguientes pasos:

1. Definir un vector  $D$ , para guardar las distancias e inicializarlo con un valor infinito relativo, ya que las distancias son desconocidas en un principio, excepto para el vértice inicial  $v_0$ , el cual tiene una distancia de cero [16].
2. Sea  $\alpha$ , el vértice actual. Se recorren todos los vértices adyacentes, marcando los ya visitados y los no visitados  $v_j$  [16].
3. Si la distancia desde  $v_0$  hasta  $v_j$  guardada en el vector  $D$ , es mayor que la distancia desde  $v_0$  hasta a sumada a la distancia desde  $\alpha$  hasta  $v_j$ , se sustituye el valor de la distancia  $D_j$  por el valor de distancia  $D_\alpha + d(\alpha, v_j)$  es decir: Si  $(D_j > D_\alpha + d(\alpha, v_j))$  entonces  $(D_j = D_\alpha + d(\alpha, v_j))$  [16].
4. Se marca el vértice  $\alpha$  como vértice ya visitado y se toma como próximo vértice a visitar al de menor valor en el vector  $D$ , repitiendo el tercer paso mientras existan vértices no marcados [16].

## 6.6. Algoritmo de Braitenberg

El Vehículo de Braitenberg tiene dos ruedas actuadas por motores independientes, y varios sensores de luz o distancia y que a mayor intensidad de luz o menor distancia, mayor par aplicado a las ruedas, y en consecuencia se genera un movimiento de las ruedas a mayor velocidad angular. Este tipo de vehículos se guían por instintos, entendiendo que un instinto se corresponde con un sistema de valores de intensidades variables, es decir un sistema de motivaciones y gustos [17].

Suponiendo un robot que funciona con sensores de luz, este puede realizar un movimiento circular alrededor de una fuente de luz externa si la función de activación tiene un máximo en algún punto, es decir si funciona con una polaridad positiva para valores de intensidad de la luz bajas y con polaridad negativa para intensidades elevadas. Si la conexión es contra lateral, se acercará a la fuente de luz cuando esté lejos de ella, y se alejará de ella cuando esté más próximo [17].

Si el anterior robot dispusiese además de otros sensores con funciones de activación diversas, el conjunto de comportamientos que podrían realizar sería muy variado, hasta el punto de que resultaría difícil, si no imposible, para un observador externo deducir esta variedad de comportamientos a partir del análisis de los elementos del robot. La dificultad de segmentar los comportamientos mediante técnicas analíticas es una de las características principales de los vehículos de Braitenberg [17].

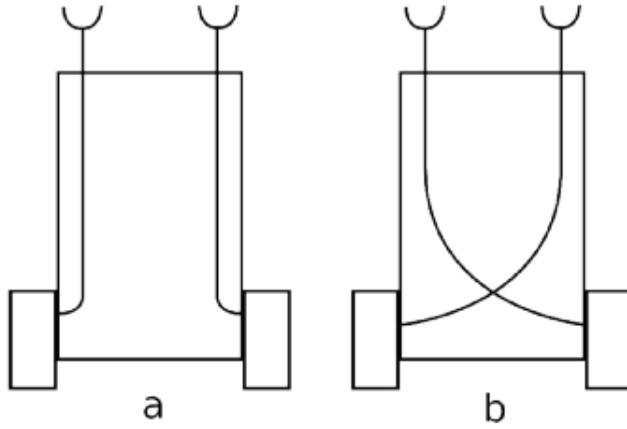


Figura 3: Diagrama de braitenberg [17].

## 6.7. Controlador PID

Un control PID se basa en un modelo matemático riguroso de algún proceso lineal o lineal dentro de un rango. Estos modelos se desarrollan ya sea por Root-Locus, ubicación de polos, o algún otro método, y si la planta se puede representar por un sistema de primer orden con retardo. El diseño del controlador puede ser realizado de manera empírica (sin conocimiento del modelo), mediante el método de Ziegler-Nichols o algún derivado de este, y se pueden asignar los coeficientes proporcional, integral y derivativo del controlador del sistema [18].

Un control PID lee un valor de entrada o del sensor de entrada, aplica los algoritmos de control, definidos y produce una salida específica como señal actuante o como entrada a un actuador. La salida del sistema es medida por el sensor de entrada, y el proceso se repite indefinidamente. El controlador PID clásico tiene la forma:

$$u = K_p \left( e + \frac{1}{T_i} \int_{x=0}^t edt + T_d \frac{de}{dt} \right) \quad (7)$$

En donde “ $e$ ” es el error entre el valor de referencia y la salida del sistema, “ $u$ ” es la salida del controlador, “ $K_p$ ” la ganancia proporcional, “ $T_i$ ” el tiempo integral, y “ $T_d$ ” el tiempo derivativo, existiendo diversos métodos para ajustar los tres parámetros de interés, siendo el de Ziegler-Nichols el origen de todos ellos [18].

En este tipo de controlador, la ganancia  $K_p$  que afecta el componente proporcional, reduce el tiempo de crecimiento y elimina “parte” del error estacionario, “ $K_i = \frac{1}{T_i}$ ” que afecta el componente integral, elimina el error en estado estacionario pero puede tener como efecto secundario una afectación de la respuesta transitoria, y “ $K_d = T_d$ ” que afecta el componente derivativo, reduce el sobre pico y mejora la respuesta transitoria, esto se puede observar en el Cuadro 1.

	$T_r$	$M_p$	$T_s$	$e_{ee}$
$K_p$	Disminuye	Aumenta	Poco Efecto	Disminuye
$K_i$	Disminuye	Aumenta	Aumenta	Elimina
$K_d$	Poco Efecto	Disminuye	Disminuye	Poco Efecto

Cuadro 1: efecto de las constantes en la salida del sistema [18].

En controladores digitales, la ecuación del controlador PID puede ser reemplazada por:

$$u = K_p \left( e(k) + K_i \sum_{j=1}^n e(j)T_s + K_d \frac{e(k) - e(k-1)}{T_s} \right) \quad (8)$$

Cambiando la derivada por una diferencia hacia atrás, la integral por una suma, y un tiempo de muestreo pequeño, siendo “ $u$ ” el instante de tiempo.

## 6.8. Regulador Cuadrático Lineal

### 6.8.1. Espacio de estados

En ingeniería de control, el control clásico se analiza por conveniencia en el dominio de la frecuencia, y está limitado a sistemas lineales con una única entrada y una única salida. La representación de espacios de estado proporciona un modo compacto y conveniente de modelar y analizar sistemas con múltiples entradas y salidas, tanto para sistemas lineales como no lineales [19].

Una representación de espacios de estados es un modelo matemático de un sistema físico descrito mediante un conjunto de entradas, salidas y variables de estado relacionadas por ecuaciones diferenciales de cualquier orden en el dominio del tiempo, que se combinan en una ecuación diferencial matricial de primer orden. Las variables de entradas, salidas y estados son convenientemente expresadas como vectores: un vector de entrada, un vector de salida y un vector de estados; y si el sistema dinámico es lineal e invariante en el tiempo, las ecuaciones algebraicas se escriben en forma matricial [19].

En el caso de sistemas lineales continuos se puede suponer que el comportamiento dinámico de un sistema se puede expresar como una ecuación diferencial de orden  $n$  que establece la relación entre la entrada  $u$  y la salida del sistema:

$$y^{(n)}(t) + a_{n-1}y^{(n-1)}(t) + \cdots + a_1y^{(1)}(t) + a_0y(t) = b_0u(t) + \cdots + b_mu^{(m)}(t) \quad (9)$$

Las técnicas de al representación en el espacio de estado o representación interna se basan en la propiedad que cumplen los sistemas y procesos según la cual siempre es posible utilizar un sistema de ecuaciones diferenciales de primer orden para representar un sistema de orden mayor. De esta forma, en vez de tener una ecuación diferencial de  $n$ -ésimo orden, se tendrán  $n$  ecuaciones diferenciales de primer orden [19]. Cada una de estas  $n$  ecuaciones

tendrá la forma general siguiente:

$$\frac{dx_i(t)}{dt} = \sum_{j=1}^n \alpha_{ij}x_j(t) + \beta_i u(t) \quad (10)$$

con:

$$y(t) = \sum_{j=1}^n c_j x_j(t) \quad (11)$$

Estas  $n$  ecuaciones diferenciales se pueden expresar con una única ecuación matricial:

$$\begin{bmatrix} \dot{x}_1(t) \\ \dot{x}_2(t) \\ \vdots \\ \dot{x}_n(t) \end{bmatrix} = \begin{bmatrix} \alpha_{11} & \alpha_{12} & \alpha_{13} & \cdots & \alpha_{1n} \\ \alpha_{21} & \alpha_{22} & \alpha_{23} & \cdots & \alpha_{2n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \alpha_{n1} & \alpha_{n2} & \alpha_{n3} & \cdots & \alpha_{nn} \end{bmatrix} * \begin{bmatrix} x_1(t) \\ x_2(t) \\ \vdots \\ x_n(t) \end{bmatrix} + \begin{bmatrix} \beta_1(t) \\ \beta_2(t) \\ \vdots \\ \beta_n(t) \end{bmatrix} u(t) \quad (12)$$

A la ecuación anterior se le suele definir como ecuación de estado del sistema la cual fija la evolución del estado en función del valor actual de dicho estado y de la aportación de la entrada [19]. Esta ecuación se puede presentar en forma matricial y compacta, obteniendo finalmente las siguientes expresiones:

$$\dot{x}(t) = Ax(t) + Bu(t) \quad (13)$$

$$y(t) = Cx(t) + Du(t) \quad (14)$$

En donde:

- $A$  = matriz  $(n \times n)$  de estado
- $B$  = matriz  $(n \times 1)$  de entrada
- $C$  = matriz  $(1 \times n)$  de salida
- $D$  = matriz  $(n \times 1)$  de acoplamiento (usualmente es un matriz nula)

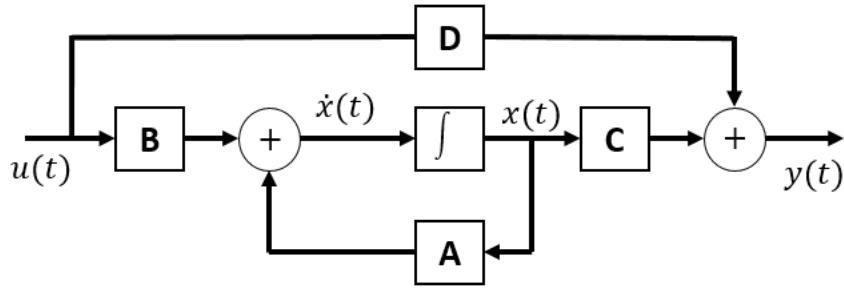


Figura 4: modelo del espacio de estados [20]

### 6.8.2. Regulador cuadrático lineal (LQR)

El regulador cuadrático lineal es un controlador por retroalimentación que busca llevar al sistema a un estado determinado de forma rápida y reduciendo la cantidad de control utilizado. El controlador LQR debe utilizar un proceso de optimización que determine el desempeño del mismo [21]. La función que se utiliza es el índice de desempeño dada por:

$$J(t_0) = \frac{1}{2}x^T(T)S(T)x(T) + \frac{1}{2} \int_{t_0}^T (x^T Q x + u^T R u) dt \quad (15)$$

En el controlador LQR, las matrices de peso  $Q$  y  $R$  se convierten en los parámetros de diseño. La matriz  $Q$  es la matriz de peso para los estados intermedios, la matriz  $R$  es la matriz de peso para la acción de control del sistema y la matriz  $S(T)$  representa el peso del estado final  $x(T)$  [21]. La dinámica de la planta es:

$$\dot{x}(t) = Ax(t) + Bu(t) \quad t \geq t_0 \quad (16)$$

$$u(t) = -Kx(t) \quad (17)$$

Para lograr el objetivo de control se necesita determinar una ley de control  $u(t)$  que minimice  $J(t_0)$ . Si se considera que la ecuación diferencial de Riccati tiene una solución en estado estacionario, el problema ahora se convierte en un problema de horizonte en infinito en donde la ecuación diferencial de Riccati (DRE) se torna en una ecuación algebraica de Riccati (ARE) de la forma:

$$-\dot{S} = A^T S + S A - S B R^{-1} B^T S + Q \quad \Rightarrow \quad 0 = A^T S + S A - S B R^{-1} B^T S + Q \quad (18)$$

Con índice de desempeño:

$$J = \int_{t_0}^{\infty} (x^T Q x + u^T R u) dt \quad (19)$$

En la ecuación anterior ya no es necesario pesar el estado final ya que, cuando el sistema es asintóticamente estable,  $x(t) \rightarrow 0$  según  $t \rightarrow \infty$  [21]. Resolviendo la ecuación 18 se obtiene el valor de la ganancia de Kalman mediante:

$$K_{\infty} = R^{-1} B^T S_{\infty} \quad (20)$$

finalmente, la acción de control para el controlador LQR con horizonte en infinito en sistema a lazo cerrado es:

$$\dot{x}(t) = (A - BK_{\infty})x(t) \quad (21)$$

## 6.9. Integrador cuadrático lineal (LQI)

Básicamente es similar al LQR, sin embargo, en este controlador, la ley de control se expresa en la ecuación 22 donde  $x_i$  es la salida del integrador. Esta ley de control asegura que la salida “ $y$ ” siga el comando de referencia o punto de consigna, el número de integradores es igual a la dimensión de la salida “ $y$ ” [22].

$$u = -K[x; x_i] \quad (22)$$

Esta ley de control adicionalmente minimiza las funciones de coste que se muestran en la siguiente ecuación:

$$J(u) = \sum_{n=0}^{\infty} \{ z^T Q_z + u^T R_u + 2z^T N_u \} \quad (23)$$

En tiempo discreto, el algoritmo LQI calcula la salida del integrador  $x_i$  usando la fórmula de avance de Euler como se indica en la ecuación 24, en donde  $T_s$  es el tiempo de muestreo del sistema [22].

$$x_i[n+1] = x_i[n] + T_s(r[n] - y[n]) \quad (24)$$

Tomando esta discretización del algoritmo se procede a encontrar los valores de las matrices del sistema LTI con la ecuación 25 y se plantea el error del sistema calculando la diferencia entre la referencia y la salida del sistema como se observa en la ecuación 26.

$$\begin{bmatrix} \dot{x}(t) \\ \dot{x}_i(t) \end{bmatrix} = \begin{bmatrix} A_{n \times n} & O_{n \times p} \\ -C_{p \times n} & O_{p \times p} \end{bmatrix} \begin{bmatrix} x(t) \\ x_i(t) \end{bmatrix} + \begin{bmatrix} B_{n \times n} \\ O_{p \times n} \end{bmatrix} u(t) + \begin{bmatrix} O_{n \times p} \\ I_{p \times p} \end{bmatrix} r(t) \quad (25)$$

$$e(t) = r(t) - y(t) = r(t) - Cx(t) \quad (26)$$

Finalmente, se puede utilizar el mismo cálculo del regulador lineal cuadrático (LQR) para obtener el valor de la matriz  $K$  tomando los nuevos valores de las matrices  $A$  y  $B$  del sistema. Obteniendo como resultado la siguiente ecuación:

$$u = -Kx = \begin{bmatrix} K_{m \times n} \\ K_{I_m \times p} \end{bmatrix} \begin{bmatrix} x_{n \times 1} \\ x_{I_p \times 1} \end{bmatrix} = -Kx - K_i x_i \quad (27)$$

## 6.10. Robot Diferencial E-Puck



Figura 5: robot e-puck[23].

El E-Puck es un robot diferencial móvil desarrollado por la Escuela Politécnica Federal de Lausana (EPFL). Este robot esta incluido en la librería de Webots para realizar simulaciones. Este robot cuenta con una gran variedad de sensores que lo hacen una buena opción para su implementación con el algoritmo PSO. Es un robot pequeño y su programación es amigable con el usuario, por lo cual ha sido utilizado como herramienta de aprendizaje [24].

El e-puck cuenta con las siguientes características:

Características	Valor
Diámetro	70 mm
Altura	55 mm
Radio de la rueda	20.5 mm
Largo del eje	52 mm
Peso	0.15 Kg
Velocidad máxima de rotación	0.25 m/s
Velocidad máxima de giro	6.28 rad/s

Cuadro 2: características físicas del robot e-puck [25].

## 6.11. Modelado de robots diferenciales

Uno de los sistemas más usuales se basa en el uso de ruedas de tracción, el cual es un sistema poco complejo y adecuado para la navegación en algunos entornos de desarrollo típicos de actividades humanas, por ejemplo oficinas, bodegas y otros. Las configuraciones de tracción diferencial, son muy populares y permiten calcular la posición del robot a partir de las ecuaciones geométricas, que surgen de la relación entre los componentes del sistema de propulsión y de la información de los codificadores rotativos que usualmente llevan acoplados a sus ruedas.

Típicamente una plataforma móvil de tracción diferencial cuenta con dos pares de ruedas: dos ruedas de tracción que tienen acoplados dos motores DC, dos ruedas de estabilización que mantienen el balance del vehículo. La traslación y rotación de este tipo de plataformas diferenciales se determinan por el movimiento independiente de cada una de las ruedas de tracción [26].

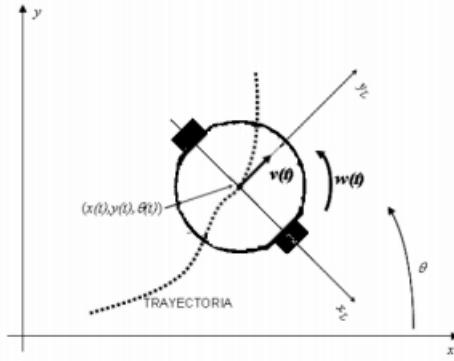


Figura 6: Localización del robot en el plano cartesiano [26]

Las ecuaciones cinemáticas del punto medio del eje entre las ruedas activas, referidas a un sistema de referencia global como se muestra en la Figura 6 son :

$$\dot{x} = v(t)\cos(\theta(t)) \quad (28)$$

$$\dot{y} = v(t)\sin(\theta(t)) \quad (29)$$

$$\dot{\theta} = \omega(t) \quad (30)$$

La posición y orientación del robot móvil se obtiene integrando las velocidades de éste en un periodo de tiempo  $\Delta t$  como se observa en las siguientes ecuaciones [26]:

$$x(t) = x(t_0) + \int_{\Delta t} v(t)\cos(\theta(t))dt \quad (31)$$

$$y(t) = y(t_0) + \int_{\Delta t} v(t)\sin(\theta(t))dt \quad (32)$$

$$\theta(t) = \theta(t_0) + \int_{\Delta t} \omega(t)dt \quad (33)$$

Si el periodo de observación  $\Delta t$ , tiende a 0, entonces las integrales anteriores pueden ser remplazadas por los desplazamientos diferenciales  $\Delta x$ ,  $\Delta y$ ,  $\Delta\theta$ . Si se mantiene una frecuencia de muestreo constante y elevada sobre la odometría de un móvil, se puede estimar la posición y orientación del mismo mediante las ecuaciones de diferencias (34), (35) y (36). Además se puede considerar que la velocidad angular en cada una de las ruedas se mantiene constante durante el periodo de muestreo [26].

$$x_k = x_{k-1} + \Delta x_k \quad (34)$$

$$y_k = y_{k-1} + \Delta y_k \quad (35)$$

$$\theta_k = \theta_{k-1} + \Delta\theta_k \quad (36)$$

## 6.12. Funciones de costo

En matemáticas aplicadas, las funciones de prueba, conocidas como paisajes artificiales, son útiles para evaluar características de algoritmos de optimización, tales como:

- Tasa de convergencia
- Precisión
- Robustez
- Rendimiento general

Las siguientes funciones de prueba tienen el objetivo de dar una idea de las diferentes situaciones a las que se enfrentan los algoritmos de optimización a la hora de afrontar este tipo de problemas y verificar que son capaces de converger al mínimo global de la función de costo.

### 6.12.1. Función de esfera

$$f(x) = \sum_{i=1}^n x_i^2 \quad f(x_1, \dots, x_n) = 0 \quad (37)$$

La función de esfera se representa en la ecuación (37), es adecuada para la optimización de objetivo único, lo que significa que presenta una función de objetivo único. Además, la función de la esfera es unimodal. Esto significa que presenta un “modo” y tiene un único óptimo global [27]. Esta función se resuelve con los métodos clásicos de optimización mucho más rápido y se puede observar en la Figura 7.

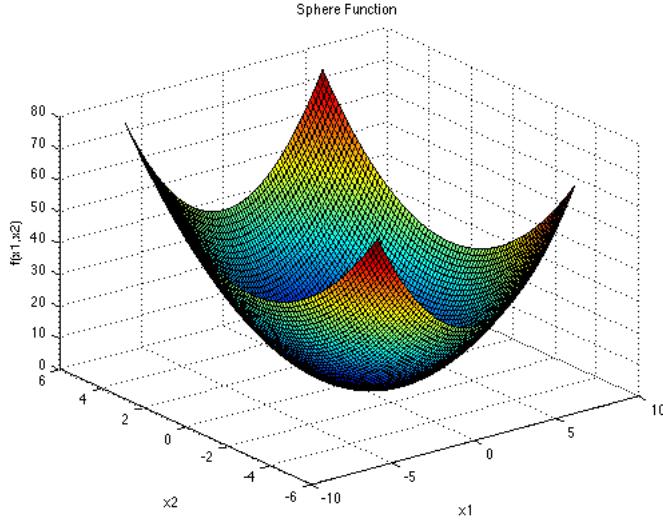


Figura 7: Comportamiento de la función de esfera [27].

### 6.12.2. Función de Rosenbrock

$$f(x) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2] \quad \text{Min} = \begin{cases} n = 2, & f(1, 1) = 0, \\ n = 3, & f(1, 1, 1) = 0, \\ n > 3, & f(1, \dots, 1) = 0 \end{cases} \quad (38)$$

En optimización matemática, la función de Rosenbrock es una función no convexa, introducida por Howard H. Rosenbrock en 1960, que se utiliza como un problema de prueba de rendimiento para algoritmos de optimización. También se conoce como el valle de Rosenbrock o la función del plátano de Rosenbrock. El mínimo global está dentro de un valle plano largo, estrecho y de forma parabólica como se observa en la Figura 8. Encontrar el valle es trivial y converger al mínimo global es difícil [27].

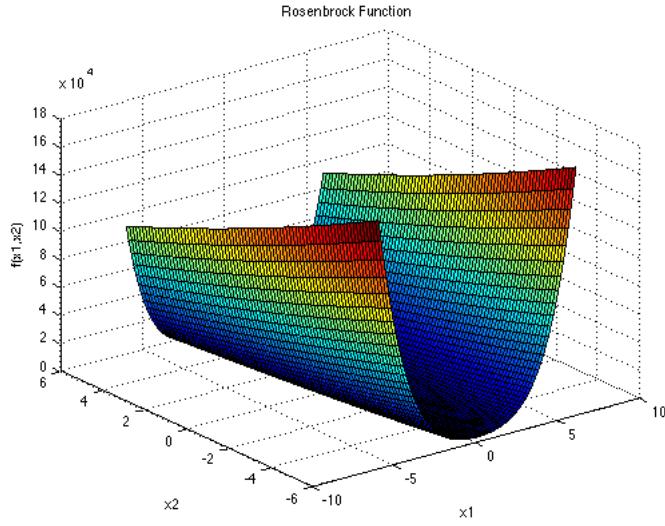


Figura 8: Comportamiento de la función de Rosenbrock [27].

### 6.12.3. Función de Booth

$$f(x) = (x + 2y - 7)^2 + (2x + y - 5)^2 \quad f(1, 3) = 0 \quad (39)$$

La función de booth se representa en la ecuación (39), esta función es usualmente evaluada en el cuadro  $x_i \in -10, 10$  para todos los valores de  $i = 1, 2, \dots, n$ . Como se puede observar, posee el mínimo absoluto descentrado del origen [27].

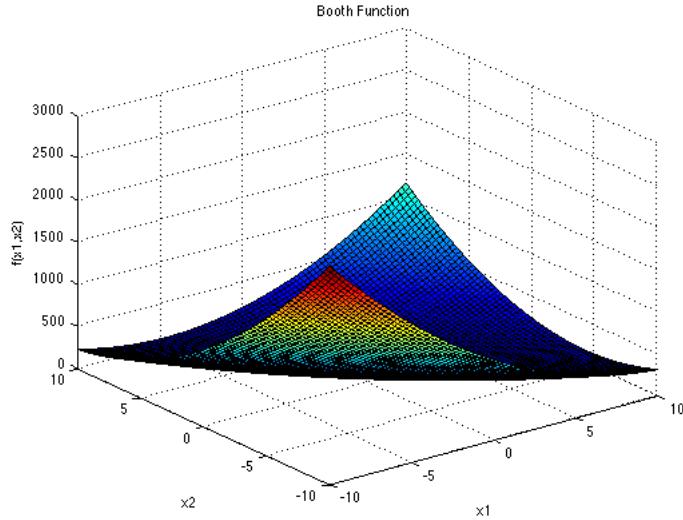


Figura 9: Comportamiento de la función de booth [27].

#### 6.12.4. Función de Himmelblau

$$f(x) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2 \quad \text{Min} = \begin{cases} f(3, 2) = 0, \\ f(-2.805, 3.1313) = 0, \\ f(-3.779, -3.283) = 0, \\ f(3.584, -1.848) = 0 \end{cases} \quad (40)$$

Esta función de costos posee múltiples mínimos que poseen el mismo valor. Por lo tanto, todos son mínimos absolutos. Es útil para determinar influencia de posición inicial de partículas sobre decisión de punto de convergencia final. Esta función es usualmente evaluada en  $-5 \leq x, y \leq 5$  [27].

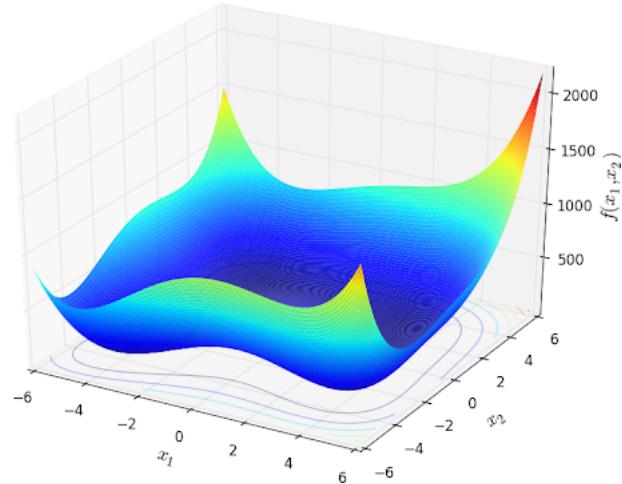


Figura 10: Comportamiento de la función de Himmelblau [27].

#### 6.13. Webots

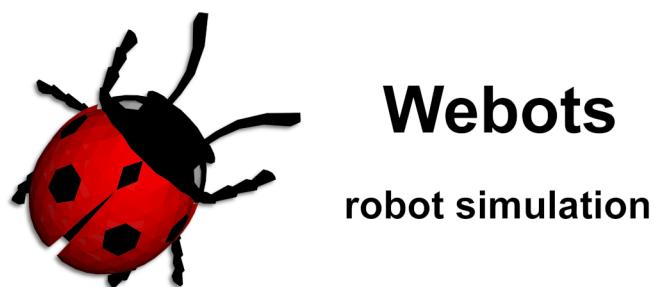


Figura 11: Logo de Webots [28].

Webots es una Multi-plataforma Open-Source (Código abierto) utilizada para realizar simulaciones de robots en entornos mas cercanos a la realidad. Provee un entorno completo de desarrollo para modelar, programar y simular robots. Esta plataforma fue desarrollada por el Dr. Oliver Michel del Instituto Federal Suizo de Tecnología para fines educativos. Utiliza el Open Dynamics Engine que Permite la simulación de colisiones y la dinámica de cuerpos rígidos creando así un entorno mas real. El programa permite utilizar controladores escritos en C, C++, Java, Python, MATLAB y ROS [28].

Webots utiliza nodos para representar cada una de sus funciones dentro del entorno. Los nodos en webots se basan en la sintaxis del estándar VRML97. Webots utiliza un subconjunto de nodos y campos definidos por el estandar VRML97, pero también es posible especificar un nodo dentro de las definiciones de un robot en específico[29].

El VRML o *Virtual Reality Modeling Language* es un formato de archivos enfocado en describir la interacción de objetos 3D y mundos virtuales. VRML fue diseñado para ser utilizado en la internet, intranet o sistemas locales. VRML busca ser un formato de intercambio universal para gráficas 3D integradas y multimedia [30].

VRML es capaz de representar objetos 3D animados y estáticos con hipervínculos dirigidos a media como textos, sonidos, películas o imágenes. VRML admite un modelo de extensibilidad que permite definir nuevos objetos 3D dinámicos, lo que permite que las comunidades de aplicaciones desarrollen extensiones interoperables para el estándar base. Las asignaciones entre los objetos VRML y las características de la interfaz del programador de aplicaciones (*Application Programmer Interface -API*) 3D de uso común [30].

## 6.14. Robot Operating System (ROS)

Robot Operating System (ROS) es una colección de marcos para el desarrollo de *software* de robots. ROS se desarrolló originariamente en 2007 bajo el nombre de switchyard por el Laboratorio de Inteligencia Artificial de Stanford para dar soporte al proyecto del Robot con Inteligencia Artificial de Stanford (STAIR2). Desde 2008, el desarrollo continuó principalmente en Willow Garage, un instituto de investigación robótico con más de veinte instituciones colaborando en un modelo de desarrollo federado [31].

Los procesos ROS se representan como nodos (*ROS nodes*) en una estructura gráfica, conectados por bordes llamados temas (*ROS topics*). Los ROS nodos pueden pasar mensajes entre sí a través de los temas, realizar llamadas de servicio a otros nodos, proporcionar un servicio para otros nodos o establecer o recuperar datos compartidos de una base de datos común llamada servidor de parámetros. Un proceso llamado maestro (*ROS Master*) hace que todo esto sea posible al registrar nodos para sí mismo, configurar la comunicación de nodo a nodo para los temas y controlar las actualizaciones del servidor de parámetros [32].

A pesar de no ser un sistema operativo, ROS provee los servicios estándar de uno de estos tales como la abstracción del *hardware*, el control de dispositivos de bajo nivel, la implementación de funcionalidad de uso común, el paso de mensajes entre procesos y el mantenimiento de paquetes. Está basado en una arquitectura de grafos donde el procesamiento toma lugar en los nodos que pueden recibir, mandar y multiplexar mensajes de sensores, control,

estados, planificaciones y actuadores, entre otros [32].

La librería está orientada para un sistema UNIX (Ubuntu -Linux-). ROS tiene dos partes básicas: la parte del sistema operativo (ROS) y ros-pkg. El ros-pkg consiste en un conjunto de paquetes aportados por la contribución de usuarios (organizados en conjuntos llamados pilas o *stacks*) que implementan las funcionalidades tales como localización y mapeo simultáneo, planificación, percepción, simulación, etc. Debido a esto es un sistema bastante completo para la realización de diversas simulaciones las cuales nos brindan resultados muy confiables y similares a lo que se vería en la vida real [31].

Al igual que Webots, ROS utiliza nodos para realizar la comunicación entre sus diferentes componentes. Un “nodo” es un proceso que realiza cálculos. Los nodos se combinan en un gráfico y se comunican entre sí mediante la transmisión de temas (*topics*), Servicios RPC (*RPC services*) y el Servidor de parámetros (*Parameter Server*). Estos nodos están destinados a operar a una escala detallada; un sistema de control de robot generalmente comprenderá muchos nodos. Por ejemplo, un nodo controla un telémetro láser, un nodo controla los motores de la rueda del robot, un nodo realiza la localización, un nodo realiza la planificación de la ruta, un nodo proporciona una vista gráfica del sistema, etc [33].

El uso de nodos en ROS proporciona varios beneficios al sistema en general. Existe una “tolerancia a fallos” adicional, ya que los bloqueos se aíslan en nodos individuales. La “complejidad del código” se reduce en comparación con los sistemas monolíticos. Los detalles de implementación también están bien ocultos, ya que los nodos exponen una API mínima al resto del gráfico y las implementaciones alternativas, incluso en otros lenguajes de programación, pueden sustituirse fácilmente. Un nodo de ROS se escribe con el uso de una librería de cliente de ROS (*ROS client library*) como roscpp o rospy [33].

## 6.15. Gazebo

Gazebo es un simulador 3D mientras que ros sirve como una interfaz para los robots. Combinando ambos se obtiene un simulador muy completo y versátil. Con gazebo se pueden crear escenarios en 3 dimensiones con robots, obstáculos y muchos otros objetos. Gazebo utiliza múltiples motores físicos tales como ODE y Bullet para iluminación, gravedad, inercia, etc. Se puede evaluar y probar el rendimiento de los robots en situaciones peligrosas o difíciles sin dañar físicamente el robot [34].

Originalmente Gazebo fue diseñado para evaluar algoritmos de robots. Para muchas aplicaciones es esencial probar la aplicación del robot para resolver errores, vida de la batería, localización, navegación, etc. Gazebo puede modelar sensores que son capaces de “ver” el entorno, tales como sensores láser, cámaras, sensores cinéticos, etc [34].

Gazebo es de código abierto y fue un componente en *The player project* del 2004 al 2011. Gazebo se volvió independiente cuando Willow Garage apoyo el proyecto. En 2012, *Open Source Robotics Foundation* (OSRF) se convirtió en el administrador del proyecto Gazebo. En 2018 OSRF cambio su nombre a *Open Robotics* que es el actual dueño del proyecto Gazebo [34].

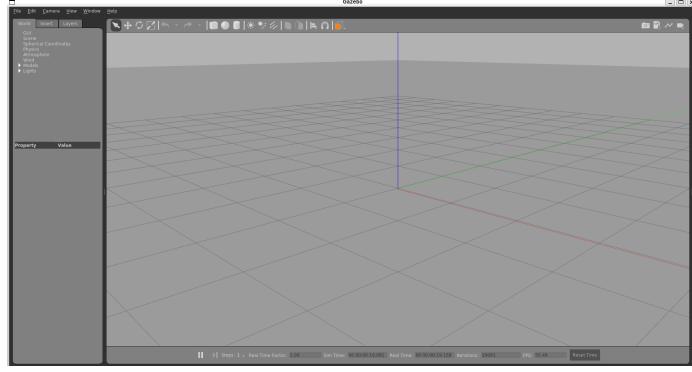


Figura 12: Entorno de Gazebo

## 6.16. Rviz

Rviz, abreviatura de visualización ROS, es una poderosa herramienta de visualización 3D para ROS. Permite al usuario ver el modelo de robot simulado, registrar la información de los sensores del robot y reproducir la información del sensor registrada. Al visualizar lo que el robot ve, piensa y hace, el usuario puede depurar una aplicación de robot desde las entradas del sensor hasta las acciones planificadas (o no planificadas)[35].

Rviz muestra datos de sensores 3D de cámaras estéreo, láseres, *Kinects* y otros dispositivos 3D en forma de nubes de puntos o imágenes de profundidad. Los datos de sensores 2D de cámaras web, cámaras RGB y telémetros láser 2D se pueden ver en rviz como datos de imagen [35].

Si un robot real se está comunicando con una estación de trabajo que ejecuta rviz, rviz mostrará la configuración actual del robot en el modelo de robot virtual. Los temas(*ROS topics*) de ROS se mostrarán como representaciones en vivo basadas en los datos del sensor publicados por las cámaras, sensores infrarrojos y escáneres láser que forman parte del sistema del robot. Esto puede ser útil para desarrollar y depurar el código base del robot [35].

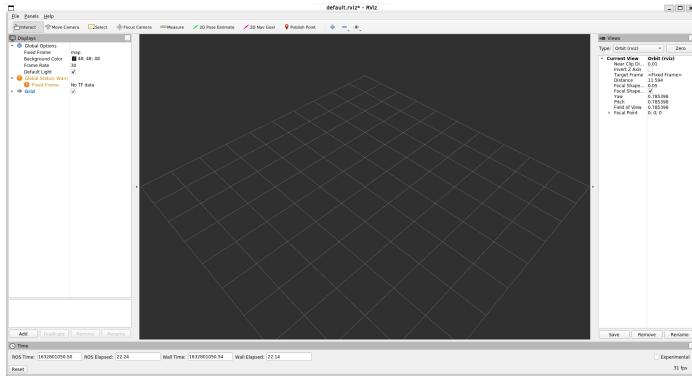


Figura 13: Entorno de Rviz

## 6.17. Lenguaje de programación XML

XML, siglas en inglés de eXtensible Markup Language (lenguaje de marcas extensible), es un lenguaje de marcas desarrollado por el World Wide Web Consortium (W3C) utilizado para almacenar datos de forma legible. XML permite definir etiquetas personalizadas para la descripción y la organización de datos. Además permite una utilización efectiva en Internet para sus diferentes terminales de una manera segura, fiable y fácil. Se puede usar en bases de datos, editores de texto, hojas de cálculo, etc [36].

Ventajas del XML:

- Es ampliable: Se puede extender fácilmente el código XML con la adición de nuevas etiquetas, de modo que se pueda continuar utilizando sin ninguna complicación [36].
- El analizador es un componente estándar, no es necesario crear un analizador específico para cada versión de lenguaje XML. Esto posibilita el empleo de cualquiera de los analizadores disponibles. De esta manera se evitan bugs y se acelera el desarrollo de aplicaciones [36].
- Al ser de estructura jerárquica, es sencillo entender su estructura y procesarla. Mejora la compatibilidad entre aplicaciones [36].
- Su análisis sintáctico es fácil debido a las estrictas reglas que rigen la composición de un documento [36].

### 6.17.1. Estructura de un documento XML

La tecnología XML mantiene la información estructurada de la forma más abstracta y reutilizable posible. Esto quiere decir que se compone de partes bien definidas, y que esas partes se componen a su vez de otras partes. Por esta razón, presenta una estructura jerárquica. A esas partes se las llaman elementos, y se las señala mediante etiquetas. Una etiqueta es una marca hecha en el documento, que señala un fragmento de éste como un elemento. Las etiquetas tienen la forma `<nombre>`, donde nombre es el nombre del elemento que se está señalando [36].

### 6.17.2. Partes de un documento XML

- **Prólogo:** Los documentos XML pueden empezar con unas líneas que describen la versión XML, el tipo de documento y otras cosas. No es obligatorio ponerlo.  
Por Ejemplo: `<?xml version="1.0" encoding="UTF-8"?>`
- **Cuerpo:** El cuerpo tiene que contener sólo un elemento raíz, característica obligatoria para que el documento esté bien formado. Sin embargo es necesaria la adquisición de datos para su buen funcionamiento.  
Por Ejemplo: `<Edit_Mensaje> (...) </Edit_Mensaje>`

- **Elementos:** Los elementos XML pueden tener contenido (más elementos, caracteres o ambos) o bien ser elementos vacíos.
- **Atributos:** Los elementos pueden tener atributos, que son una manera de incorporar características o propiedades a los elementos de un documento. Deben ir entre comillas.
- **Entidades predefinidas:** Entidades para representar caracteres especiales para que no sean interpretados como marcado en el procesador XML.  
Por Ejemplo: *entidad predefinida: & carácter: &*
- **Comentarios:** Son aclaraciones que pueden ser escritas para informar al lector, y son ignorados por el procesado. Los comentarios en XML mantienen el siguiente formato:  
*<!-- Esto es un comentario -->*

# CAPÍTULO 7

---

## Diseño experimental en Webots

---

### 7.1. Desarrollo de Algoritmo PSO

Para el desarrollo del algoritmo PSO se utilizo la posición de los robots diferenciales obtenida por un nodo de GPS que nos brinda la posición y la orientación de los robots en un momento determinado del tiempo. Se tomaron los datos de la posición del robot para comparar la mejor posición que ha tenido el robot con la posición actual del mismo ( $p_i^{mejor} - p_i(t)$ ). Este calculo se utiliza dentro de la ecuación 41.

$$v_i(t + 1) = v_i(t) + c_1 r_1 (p_i^{mejor} - p_i(t)) + c_2 r_2 (p_g^{mejor} - p_i(t)) \quad (41)$$

En el caso de la mejor posición global se utiliza un nodo transmisor y un nodo receptor dentro del entorno de webots. El nodo emisor se utiliza para modelar emisores de radio, serie o infrarrojos. Este tipo de nodos solo es capaz de enviar información pero no de recibirla. Por otro lado, un nodo receptor también se utiliza para modelar receptores de radio, serie o infrarrojos, pero a diferencia del emisor, este solo es capaz de recibir información. Si se desea tener una comunicación unidireccional entre dos robots, uno de ellos debe de poseer un nodo emisor mientras el otro debe de tener un nodo receptor. En el caso que querer tener una comunicación bidireccional, ambos robots deben de contar con un nodo emisor y un nodo receptor.

Para poder compartir los datos de la mejor posición global entre los robots se debe tener una comunicación bidireccional entre todos los robots, esto significa que todos los robots deben de tener un nodo receptor y un nodo emisor. Dentro de las configuraciones que pueden tener estos dos nodos, nos encontramos con el tamaño de los bytes, el canal por el cual se transmitirá la información, el tamaño del *buffer*, el rango, el tipo de señal, etc. En este caso, nos interesa el canal por el cual se realiza la comunicación, este es un

numero de identificación para un emisor de “infrarrojos” o una frecuencia para un emisor de “radio”. Normalmente un receptor debe utilizar el mismo canal que un emisor para recibir los datos emitidos. El canal 0 (el predeterminado) está reservado para comunicarse con un complemento de física. Debido a esto, se decidió seleccionar el canal de comunicación No.1.

Ya teniendo claro cual sera el canal que se utilizara para transmitir los datos, se procede a determinar cuales son los datos relevantes que se desean transmitir. En este caso, nos interesa transmitir la mejor posición del robot y verificar si los otros robots han tenido una mejor posición. Para esto, se determina que se necesita un *buffer* capaz de contener 3 datos, siendo estos el valor de la posición del robot y el valor obtenido por el algoritmo PSO en esa posición. Si el robot con el cual estamos comparando la posición posee un mejor valor, este valor pasa a tener el lugar de la mejor posición global de todo el arreglo de robots. A partir de estos datos se comparó la mejor posición actual del robot con la mejor posición global del arreglo. Lo cual corresponde a la segunda parte de la ecuación (41) en donde se determina la diferencia entre estos valores ( $p_g^{mejor} - p_i(t)$ ).

Con esta información ya es posible calcular las posiciones futuras de cada uno de los robots del PSO. Cabe destacar que cada robot calcula su propia función del PSO y la mejor posición del robot y la posición actual son calculadas internamente, mientras que la mejor posición global si es compartida entre todos los robots utilizando los nodos emisores y receptores dentro de cada robot.

Las constantes del algoritmo fueron obtenidas del *Toolbox* creado por Eduardo Santizo. Dentro de este *Toolbox* se calculan los valores de  $c_1$  y  $c_2$  óptimos para el algoritmo PSO los cuales son ingresados dentro de la definición en el mundo de Webots. Estos parámetros buscan una convergencia mas rápida hacia el mínimo de la función por parte de todos los robots diferenciales.

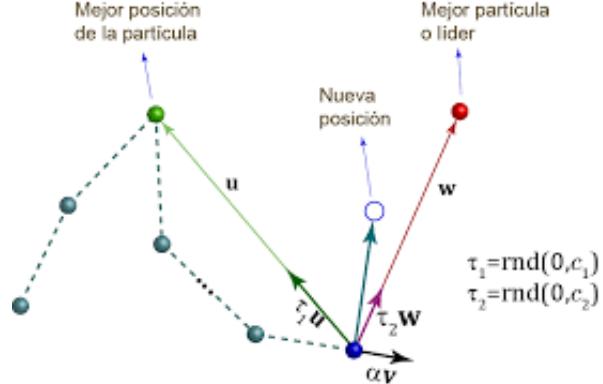


Figura 14: Representación gráfica del comportamiento del algoritmo PSO [37]

## 7.2. Algoritmo D\* Lite para evasión de obstáculos

Se logró implementar un algoritmo D\* Lite el cual era capaz de navegar por un terreno inicialmente vacío y al momento de encontrar un obstáculo cerca del robot, el algoritmo recalculaba la nueva trayectoria que debía seguir el robot para evitar colisionar con el obstáculo. Para esto, se tuvo que discretizar el espacio creando segmentos con distancia  $\delta$  tanto en el eje x como en el eje z creando así una cuadrícula con vértices hacia los cuales el robot era capaz de moverse. Se estableció  $s_{meta} = (0.75, 0.75)$  y  $s_{inicio} = (0.125, 0.125)$  en el eje x y z respectivamente. Estos puntos se pueden observar dentro del entorno de Webots en las Figuras 15a y 15b.

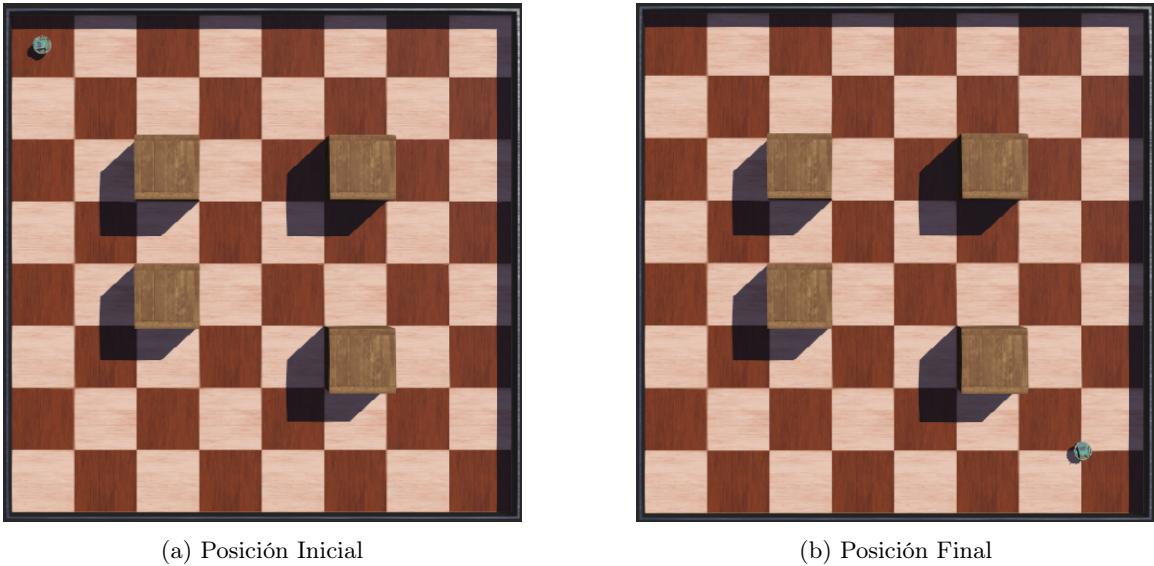


Figura 15: Posición inicial y final del robot en el *Gridworld*

Como se puede observar en las imágenes mostradas en la figura 15 el *Gridworld* consta de ocho cuadros y la extensión del terreno es de 1 metro  $\times$  1 metro. Por lo tanto se estableció un  $\delta = 0.0625$  metros para obtener una cuadrícula de  $16 \times 16$  nodos. Esta cuadrícula de  $16 \times 16$  nodos fue definida dentro del entorno de Webots en lenguaje C para establecer las posiciones a las cuales el robot es capaz de moverse dentro del entorno.

Tomando estas posiciones a las cuales se podría mover el robot se calculó el valor de  $rhs(s)$  para cada nodo. El peso de cada nodo corresponde a la distancia entre cada nodo. Se permitió el movimiento diagonal del robot a lo largo de los nodos definidos y se agregó una penalización de 1.5 para este tipo de movimientos diagonales.

Se definió una lista de prioridad de tamaño  $16^2$  lo cual nos daba una lista de 256 datos. La razón de hacer la predefinición del tamaño de las variables se debe a que el lenguaje C no se pueden utilizar arreglos dinámicos. Un arreglo dinámico es un arreglo de elementos que crece dinámicamente conforme los elementos se agregan o se eliminan.

Se realizaron simulaciones preliminares dentro del entorno de Python para evaluar la velocidad con la cual el algoritmo recalculara las trayectorias entre la posición inicial ( $s_{start}$ )

y la posición final ( $s_{final}$ ). Como se puede observar en la Figura 16 el algoritmo es capaz de recalcular de manera efectiva la trayectoria que debe tomar el robot para llegar a la posición final y la velocidad a la cual lo hace es casi instantáneo. Se puede observar todos los cambios en la trayectoria del algoritmo en las Figuras 39, 40 y 41 del anexo. Dentro de las imágenes mostradas en la Figura 16 se puede observar un cuadrado alrededor de nuestro punto móvil, este cuadrado simula la visión y el alcance de nuestros sensores dentro del entorno.

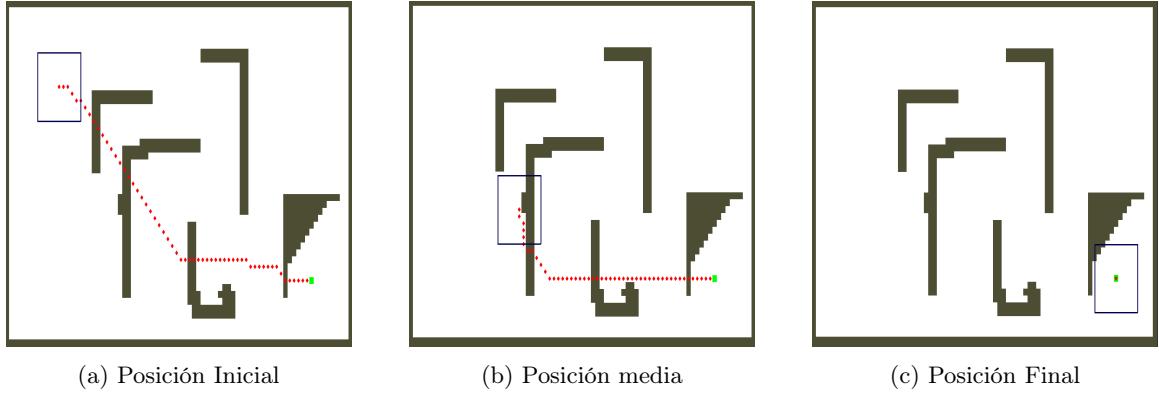


Figura 16: Trayectorias generadas por el algoritmo D\* Lite

El objetivo principal de este algoritmo es lograr que el movimiento del robot, hacia los puntos específicos brindados por algoritmo PSO, sea lo mas rápido posible mientras el sistema es capaz de evadir los obstáculos que encuentra en el camino. Al llegar al punto, el sistema calcula de nuevo el algoritmo PSO para encontrar el siguiente punto y así sucesivamente hasta lograr converger hacia el mínimo global.

### 7.3. Algoritmo de Braitenberg

Para el algoritmo de vehículos de braitenberg se utilizó robótica basada en comportamiento para generar el movimiento de evasión. La robótica basada en comportamiento es un enfoque de la robótica que se centra en aquellos robots capaces de exhibir comportamientos de apariencia compleja a pesar de pequeñas variables del estado interno para modelar su entorno, sobre todo corrigiendo gradualmente sus acciones a través de enlaces sensorio motores. Por lo tanto, mientras el robot no detecte ningún obstáculo cercano a él, seguirá moviéndose en la dirección del punto que sea nuestra meta. En el momento que el robot detecta un obstáculo cercano a él, utiliza el algoritmo de braitenberg para realizar las maniobras necesarias para evitar el obstáculo.

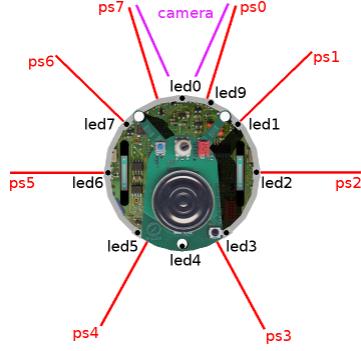


Figura 17: Sensores del robot e-puck [38]

Como se puede observar en la Figura 17, el robot e-puck cuenta con 8 sensores de distancia. Tomando en consideración que el giro del robot depende de la velocidad de la rueda derecha ( $V_r$ ) y de la rueda izquierda ( $V_l$ ). Se puede establecer que si  $V_r > V_l$  el robot realiza un giro a la derecha, si  $V_l > V_r$  el robot realiza un giro a la izquierda y si  $V_r = V_l$  el robot se mueve hacia adelante si las velocidades son positivas o hacia atrás si las velocidades son negativas. Bajo esta definición, se puede establecer el comportamiento del robot como:

$$||V_r|| = ||V_r||_0 + \sum_{k=1}^2 \frac{\alpha_{1k}(||s_k||)}{\rho}$$

$$||V_l|| = ||V_l||_0 + \sum_{k=1}^2 \frac{\alpha_{2k}(||s_k||)}{\rho}$$

En donde:

- $||V_l||_0$  = velocidad constante.
- $\rho$  = rango de los sensores (por lo general se normaliza obteniendo un valor entre 0 y 1).
- $\alpha$  = peso de cada uno de los sensores sobre cada uno de los motores.

Teniendo esto definido, se puede emplear producto matricial para encontrar la forma compacta del controlador de braitenberg, finalmente la ecuación queda de la siguiente manera:

$$\begin{bmatrix} ||V_r|| \\ ||V_l|| \end{bmatrix} = \begin{bmatrix} ||V_r||_0 \\ ||V_l||_0 \end{bmatrix} + As$$

En donde, la matriz A corresponde a los pesos de cada uno de los sensores y el vector s corresponde a los valores de cada uno de los sensores  $s_k$ , en un tiempo específico, dividido por su rango ( $\rho$ ). Para determinar los valores de la matriz de A se tomo en consideración que los sensores en la parte de atrás del robot ( $ps3, ps4$ ) relativo a la Figura 17 no se utilizarían, por

lo tanto el valor de  $\alpha = 0$  para estos sensores. Para los sensores laterales ( $ps5, ps2$ ) relativo a la Figura 17, solo requerimos que el robot gire lo suficiente para mantener un movimiento en linea recta. Finalmente para los cuatro sensores en la parte frontal ( $ps0, ps1, ps7, ps6$ ) relativo a la Figura 17, se requiere que el robot gire sobre su eje, por lo que se le asigna un peso mayor a estos sensores. Finalmente, definimos la matriz  $A$  y el vector  $s$  como:

$$A = \begin{bmatrix} \alpha_{11} & \alpha_{21} & \cdots & \alpha_{k1} \\ \alpha_{12} & \alpha_{22} & \cdots & \alpha_{k2} \end{bmatrix} = \begin{bmatrix} 0.95 & 0.8 & 0.4 & 0 & 0 & -0.2 & -0.35 & -0.45 \\ -0.5 & -0.4 & -0.2 & 0 & 0 & 0.4 & 0.75 & 0.90 \end{bmatrix}$$

$$s = \frac{1}{\rho} \begin{bmatrix} ||s_1|| & ||s_2|| & \cdots & ||s_k|| \end{bmatrix}^T$$

## 7.4. Selección de controladores

Para la selección de los controladores óptimos se realizaron una serie de simulaciones dentro del entorno de Webots para encontrar el controlador que le tomara una menor cantidad de tiempo converger hacia el mínimo global de la función. Dentro de estas simulaciones se variaron las posiciones de los obstáculos dentro del entorno de webots generando cada vez entornos más difíciles.

Como se menciono con anterioridad, se utilizo una aproximación de vehículos de braitenberg con robótica basada en comportamientos. Esto se debe a las limitaciones que presentaba el algoritmo D\* Lite a la hora de ser implementado dentro del mundo de Webots. Utilizando robótica basada en comportamientos, el robot era capaz de poder determinar, dependiendo de varios factores, si debería moverse hacia el punto o alrededor de un obstáculo.

Entre los controladores PID, LQR y LQI, se tomo en consideración tiempos de convergencia entre todos los controladores en diferentes escenarios y diversas posiciones iniciales. Esto se realizó para tener un aproximado de cuál es la variación de los datos en comparación con el cambio o la dificultad del entorno simulado.

Para los parámetros utilizados para cada uno de los controladores, se tomaron los parámetros establecidos dentro del *Toolbox* realizado por Eduardo Santizo [2] en donde establece que las constantes para el controlador PID son:

$$K_p = 0.5 \quad K_i = 0.1 \quad K_d = 0.001 \quad (42)$$

La matriz de constantes para el regulador cuadrático lineal (LQR) es igual a:

$$K_{lqr} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (43)$$

La matriz de constantes para el Integrador cuadrático lineal (LQI) es igual a:

$$K = \begin{bmatrix} 0.2127 \\ 0.2127 \end{bmatrix} \quad K_i = \begin{bmatrix} -0.0224 \\ -0.0224 \end{bmatrix} \quad (44)$$

# CAPÍTULO 8

---

## *Robotic Operating System (ROS)*

---

### 8.1. Entorno de ROS

#### 8.1.1. Comandos Básicos

La comunicación que se establece entre los nodos es gracias al *ROS Master*. El *ROS Master* proporciona servicios de nombres y registros a los nodos en el sistema ROS y realiza un seguimiento de los publicadores y suscriptores de los temas (*topics*). El papel del maestro es permitir que los nodos ROS individuales se ubiquen entre sí, para comunicarse entre sí de igual a igual [39].

Para crear un *ROS Master*, se utiliza la el comando “`roscore`”. `roscore` es una colección de nodos y programas que son requisitos para un sistema basado en ROS y se debe tener un “`roscore`” ejecutándose para que se pueda realizar la comunicación entre los diferentes nodos [39].

Para poder enviar instrucciones al robot y recibir información de sus sensores y odometría se deben crear nodos de comunicación, con distintos temas y mensajes. El comando de “`rostopic`” es una herramienta por línea de comandos que muestra información sobre los nodos ROS como se observa en la Figura 18. Incluyendo publicadores, suscriptores y conexiones [39].

```
turtlebot@turtlebot:~$ rosnode list
/app_manager
/bumper2pointcloud
/capability_server
/capability_server_nodelet_manager
/cmd_vel_mux
/diagnostic_aggregator
/interactions
/master
/mobile_base
/mobile_base_nodelet_manager
/robot_state_publisher
/rosout
/zeroconf/zeroconf
```

Figura 18: Ejemplo de visualización de los nodos de ROS [39].

Por otro lado, El comando “rqt\_graph” es una herramienta muy útil para ver lo que sucede en el gráfico ROS. Es un complemento GUI (*Graphical User Interface*) del conjunto de herramientas Rqt. Con el comando “rqt\_graph” se obtiene una visión global del sistema ROS. Esta herramienta también permite comprobar la comunicación entre los nodos y detectar posibles problemas [39]. Un ejemplo de como se observa este tipo de conexión de puede encontrar en la figura 19.

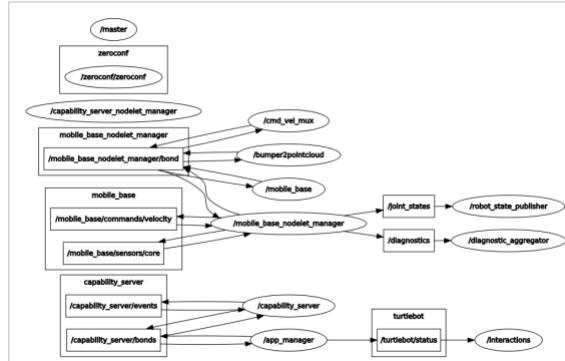


Figura 19: Ejemplo de la gráfica de conexiones entre los nodos [39].

El comando “rostopic” es otra herramienta que muestra información de los temas de ROS, incluidos los publicadores, suscriptores y mensajes ROS. Los temas son la manera que tienen los nodos de comunicarse entre ellos. A través de estos temas los nodos se pasan mensajes y pueden estar varios activos al mismo tiempo, como se observa en la Figura 20. Estos mensajes pueden tener una estructura predeterminada o bien puede ser creada por nosotros [39].

```
turtlebot@turtlebot:~$ rostopic list
/capability_server/bonds
/capability_server/events
/cmd_vel_mux/active
/cmd_vel_mux/input/navi
/cmd_vel_mux/input/safety_controller
/cmd_vel_mux/input/switch
/cmd_vel_mux/input/teleop
/cmd_vel_mux/parameter_descriptions
/cmd_vel_mux/parameter_updates
/diagnostics
/diagnostics_agg
/diagnostics_toplevel_state
/gateway/force_update
/gateway/gateway_info
/info
/interactions/interactive_clients
/interactions/pairing
/joint_states
/mobile_base/commands/controller_info
```

Figura 20: Ejemplo de visualización de los temas activos en ROS [39].

### 8.1.2. Componentes Principales

Un sistema de comunicación es a menudo una de las primeras necesidades que surgen en la implementación de una nueva aplicación robótica. El sistema de mensajería integrado de ROS le permite ahorrar tiempo mediante la gestión de los detalles de la comunicación entre los nodos distribuidos a través de publicaciones anónimas/método de suscripción. Otra ventaja de utilizar un sistema de mensajes es que obliga a implementar interfaces claras entre los nodos del sistema, mejorando así la encapsulación y la promoción de la reutilización de código . La estructura de estas interfaces de mensaje se define en el mensaje de IDL (*Interface Description Language*) [36].

Años de discusión y desarrollo de la comunidad han dado lugar a un conjunto de formatos de mensaje estándar que cubren la mayor parte de los casos de uso común en la robótica. Hay definiciones de mensajes de conceptos geométricos como poses, transformadas y vectores; para sensores como cámaras, IMU y láser; y para los datos de navegación como odometría, rutas y mapas; entre muchos otros. Estos mensajes también incrementan la interoperabilidad con las herramientas y características existentes en el ecosistema de ROS.

ROS proporciona un conjunto de herramientas para describir y modelar el robot para que pueda ser comprendido por el resto de su sistema de ROS, incluyendo tf, *robot\_state\_publisher* y *rviz* [36]. El formato para la descripción de su robot de ROS es URDF (*Unified Robot Descripción Format*), que consiste en un documento XML en el que se describen las propiedades físicas de su robot, desde la longitud de las extremidades y tamaños de ruedas a la ubicación de los sensores y la apariencia visual de cada parte del robot. Una vez que se define de esta manera, el robot se puede utilizar fácilmente con la librería tf, representada en las tres dimensiones con visualizaciones detalladas, y se utiliza con los simuladores y los planificadores de movimiento.

## 8.2. Algoritmo de dijkstra

Es un algoritmo para la determinación del camino más corto, dado un vértice origen, hacia el resto de los vértices en un grafo que tiene pesos en cada arista. Su nombre alude a Edsger dijkstra, científico de la computación de los Países Bajos que lo concibió en 1956 y lo publicó por primera vez en 1959.

El algoritmo de dijkstra es un algoritmo globalmente conocido en donde el sistema busca encontrar el camino mas corto entre un posición y otra. Debido a esto, se decidió realizar una simulación de este algoritmo dentro del entorno de ROS, para evaluar la eficiencia de la implementación de este tipo de algoritmos. El algoritmo posee dos listas en donde se incluyen los nodos abiertos o no visitados y los nodos cerrados o nodos ya visitados. Llevando un control de este tipo, el algoritmo es capaz de navegar a través de un terreno relativamente desconocido.

El único inconveniente con el algoritmo de dijkstra esta en que el algoritmo itera sobre todos los nodos del espacio hasta que encuentra el nodo en donde esta la meta. Esto conlleva mucho costo computacional debido a que el algoritmo tiene que realizar el calculo para cada nodo no visitado que este alrededor de un nodo ya visitado, independientemente si la meta se encuentra en esa dirección o no.

Tomando esto en consideración, el entorno de ROS cuenta con una herramienta visual la cual es capaz de discretizar un espacio para lograr obtener una cuadricula. Todo esto es gracias a la herramienta de Rviz dentro del entorno de ROS. Finalmente la herramienta de Rviz se comunica directamente con el simulador de Gazebo, cuando el sistema encuentra una trayectoria por la cual el robot puede pasar y luego esta información se pasa al simulador que se encarga del movimiento del robot diferencial. El espacio de búsqueda y la trayectoria generada se puede observar en la Figura 21 y el entorno en Gazebo se puede ver en 22.

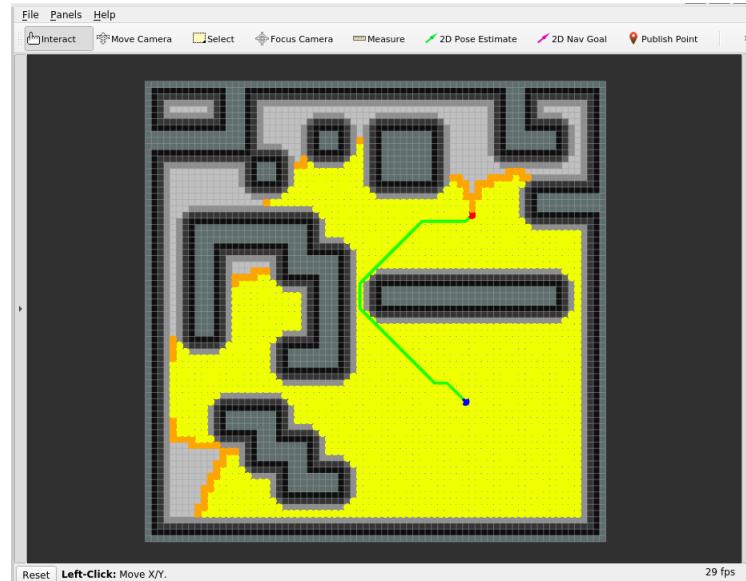


Figura 21: espacio de búsqueda y la trayectoria generada por algoritmo de Dijkstra

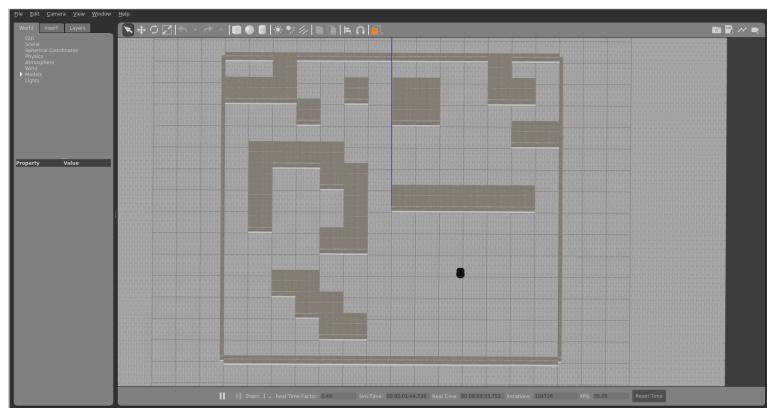
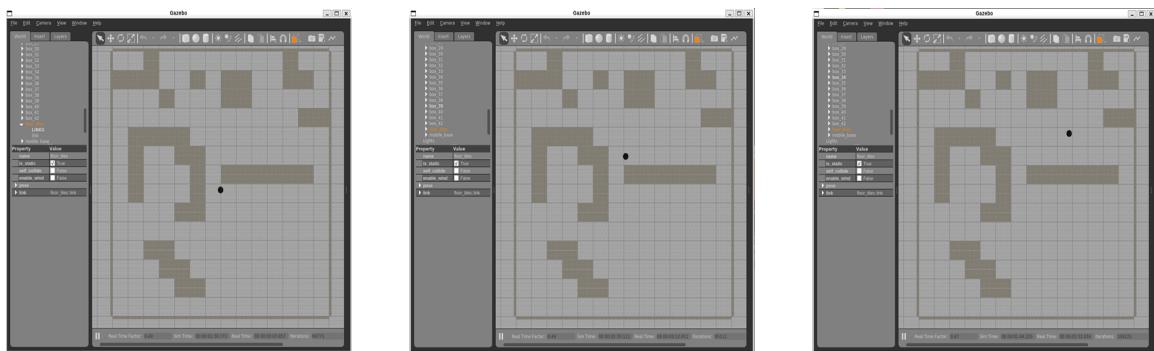


Figura 22: Espacio de simulación de Gazebo en la posición inicial

El objetivo de la implementación de este algoritmo dentro del entorno de ROS es poder establecer las bases para la implementación del algoritmo D\* Lite y posteriormente utilizarlo en conjunto con el algoritmo PSO creando un robot capaz de navegar a través de un entorno totalmente desconocido y siendo capaz de converger a la meta de forma rápida y efectiva. Como se puede observar en la Figura 23, el robot es capaz de seguir la trayectoria generada por la herramienta de Rviz.



(a) Movimiento # 1

(b) Movimiento # 2

(c) Movimiento # 3

Figura 23: Seguimiento de trayectoria de Dijkstra dentro del entorno de Gazebo

# CAPÍTULO 9

---

## Resultados

---

### 9.1. Simulación PSO sin obstáculos

Se realizaron pruebas con algoritmos básicos de PSO y controladores PID, LQI y LQR para establecer el comportamiento que deberían de tener los robots y el tiempo que le toma al algoritmo converger en cada caso. Se pueden observar los tiempos de estas simulaciones en el apartado de anexos, desde la Figura 29 - 38. El algoritmo PSO es calculado individualmente por cada uno de los robots y se mantiene una comparación constante entre la posición actual del robot ( $p_i(t)$ ) y la mejor posición que ha tenido el robot ( $p_i^{mejor}$ ). Al mismo tiempo se compara la posición actual del robot con la mejor posición global ( $p_g^{mejor}$ ). Estas comparaciones se realizan para indicarle al robot la dirección hacia donde debe moverse. El robot constantemente calcula el algoritmo de PSO de forma independiente, esto quiere decir que no existe un nodo supervisor que le indique a cada robot hacia donde moverse o que lleve el conteo del numero de partículas dentro del sistema. Esto nos presenta un problema debido a que los robots solo comparten la información de la mejor posición global y no de la posición individual de cada robot, causando así que puedan existir posibles colisiones al momento de llegar al mínimo global del sistema o que dos o más robots se crucen durante su trayectoria.

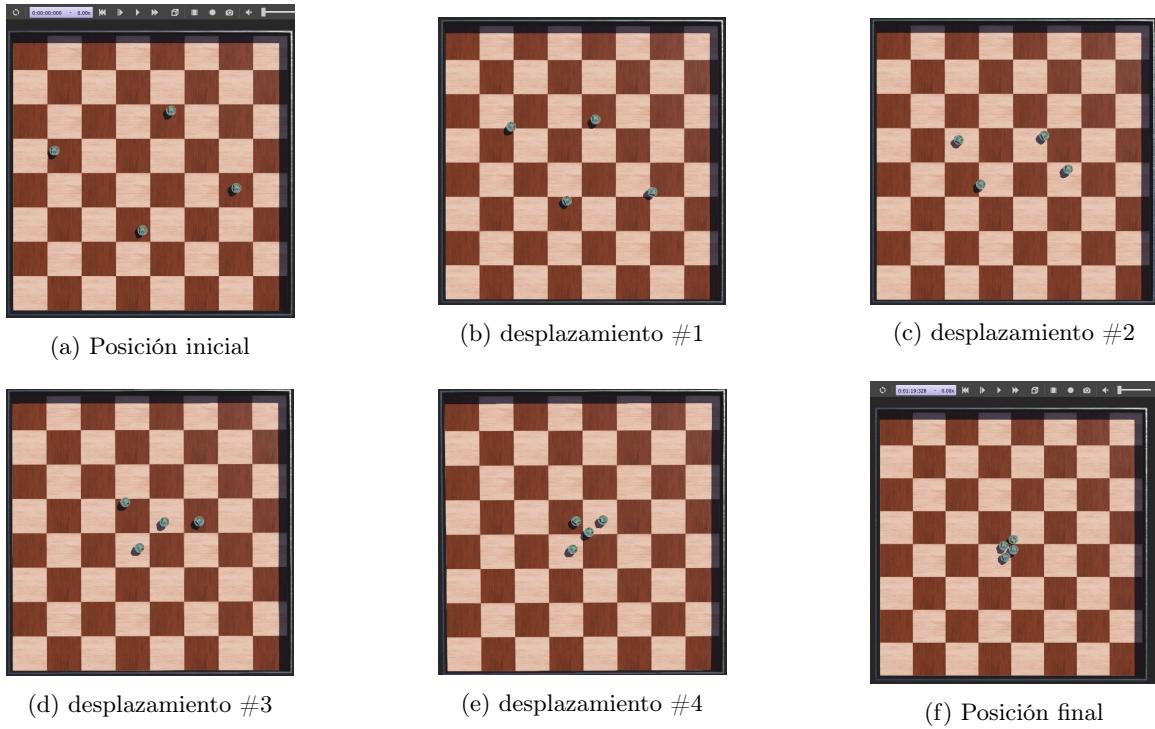


Figura 24: Trayectoria del robot utilizando un controlador PID

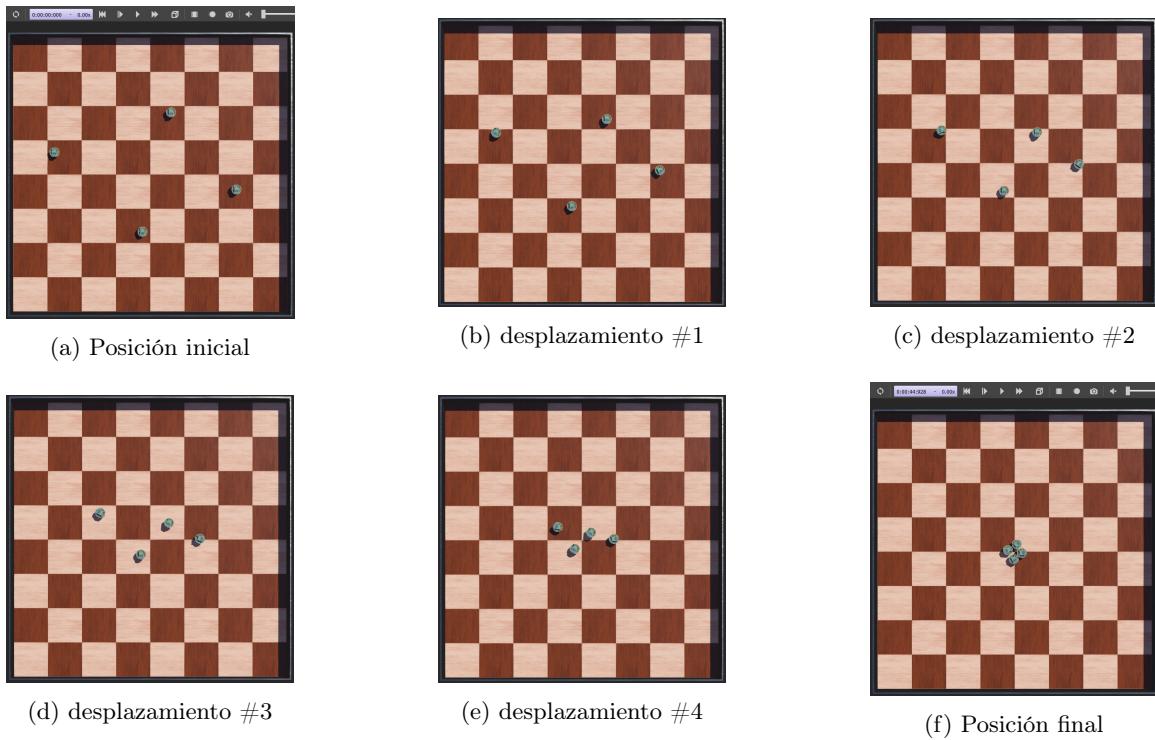


Figura 25: Trayectoria del robot utilizando un controlador LQR

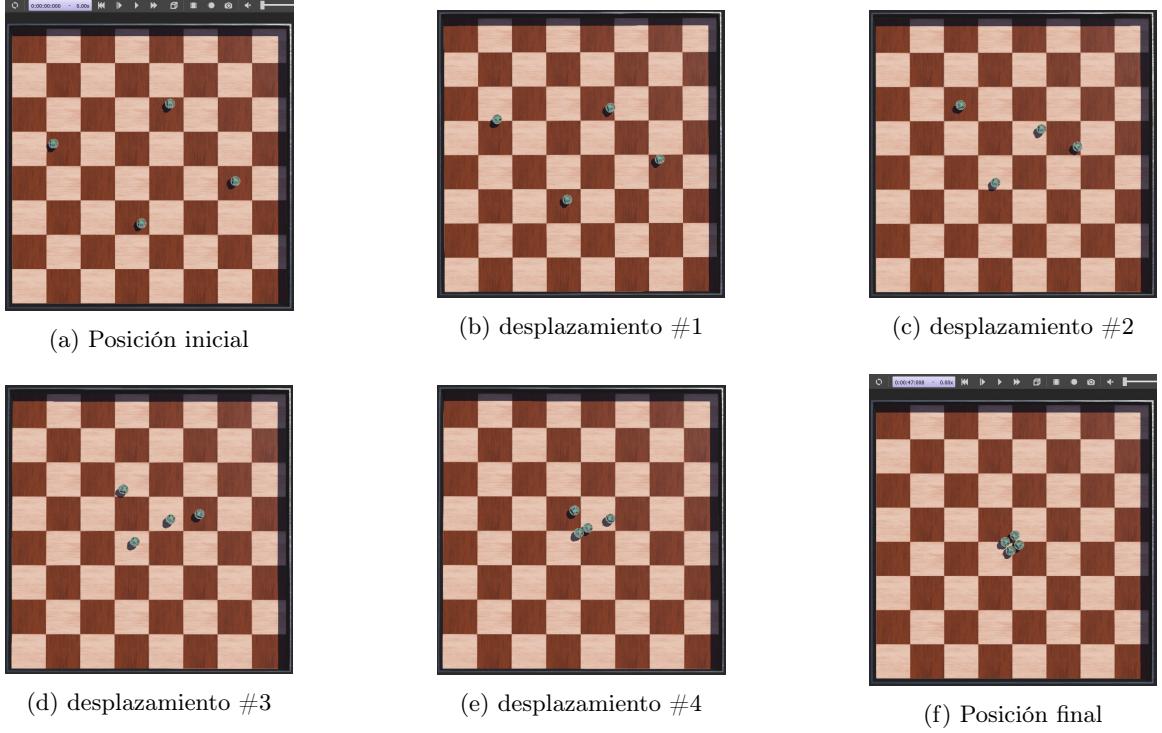


Figura 26: Trayectoria del robot utilizando un controlador LQI

En el caso de las figuras mostradas con anterioridad, la función de costo utilizada fue la función de la esfera y su mínimo global es el punto  $(0,0)$ . Como se puede observar en las figuras 24,25 y 26, todos los controladores son capaces de converger hacia el mínimo global de la función de costo. La única diferencia es el tiempo el cual les tomo a los robots en converger hacia este punto. Debido a esto se realizaron varias simulaciones para establecer los tiempos que le toma al sistema converger al mínimo global con cada uno de los controladores y estos valores se graficaron para obtener valores promedio de los tiempos. Obteniendo como resultado los siguientes valores (para mas detalle ver 29):

Controlador	Tiempo Promedio (s)
PID	29.0632
LQR	10.4672
LQI	34.8332

Tomando estos datos en consideración, se puede observar que el controlador LQR es el controlador con el menor tiempo de convergencia. Por otro lado, se puede observar que los tiempos de el controlador PID y el controlador LQI son similares siendo la diferencia 5 segundos entre uno y el otro. Esto nos brinda los parámetros base para el desarrollo de las simulaciones con el algoritmo de evasión de obstáculos. Por lo tanto, se establece que el mejor tiempo de convergencia es brindado por el controlador LQR, seguido por el controlador PID y finalmente el controlador LQI.

## 9.2. simulación de algoritmo D\* Lite

En la siguiente secuencia de imágenes se logra observar el movimiento del robot desde una posición inicial en  $(0.125, 0.125)$  y una posición final en  $(0.75, 0.75)$ .

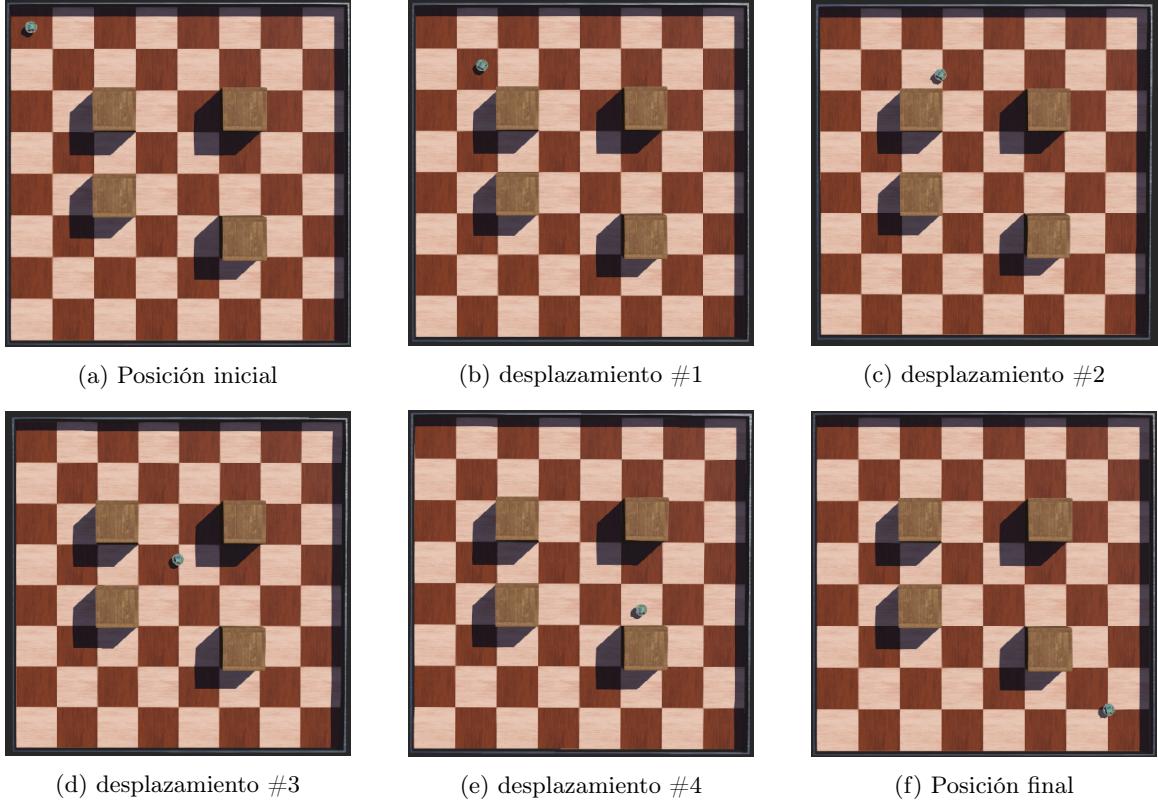


Figura 27: Trayectoria del robot utilizando el algoritmo D\* Lite

Como se puede observar en la Figura 27, el robot es capaz de navegar a través de los obstáculos siguiendo una trayectoria definida. Al momento de implementar el algoritmo D\* en conjunto con el algoritmo PSO nos encontramos con algunos problemas:

- El algoritmo PSO nos brinda el punto  $s_{meta}$  luego de ser calculado por la formula y es un punto arbitrario dentro del espacio, por lo cual era necesario discretizar el espacio con un valor de  $\delta$  muy pequeño, aumentando de manera significativa el tamaño de la matriz que contenía los nodos, lo cual causaba que el calculo fuera más tardado debido a que el algoritmo debe iterar sobre todos los nodos presentes que se vayan acercando a la  $s_{meta}$  iniciando en  $s_{inicial}$ . Por lo tanto el tiempo el cual le tomaba al algoritmo realizar los cálculos y converger era mayor.
- Durante las pruebas, se pudo observar que el algoritmo D\* tomaba a los otros robots como si fueran obstáculos, por lo cual, recalcular las trayectorias al estar cerca del punto de convergencia causaba una gran carga en el sistema y los robots se quedaban estáticos o realizando movimientos mínimos.

### 9.3. simulación de algoritmo Braitenberg y PSO

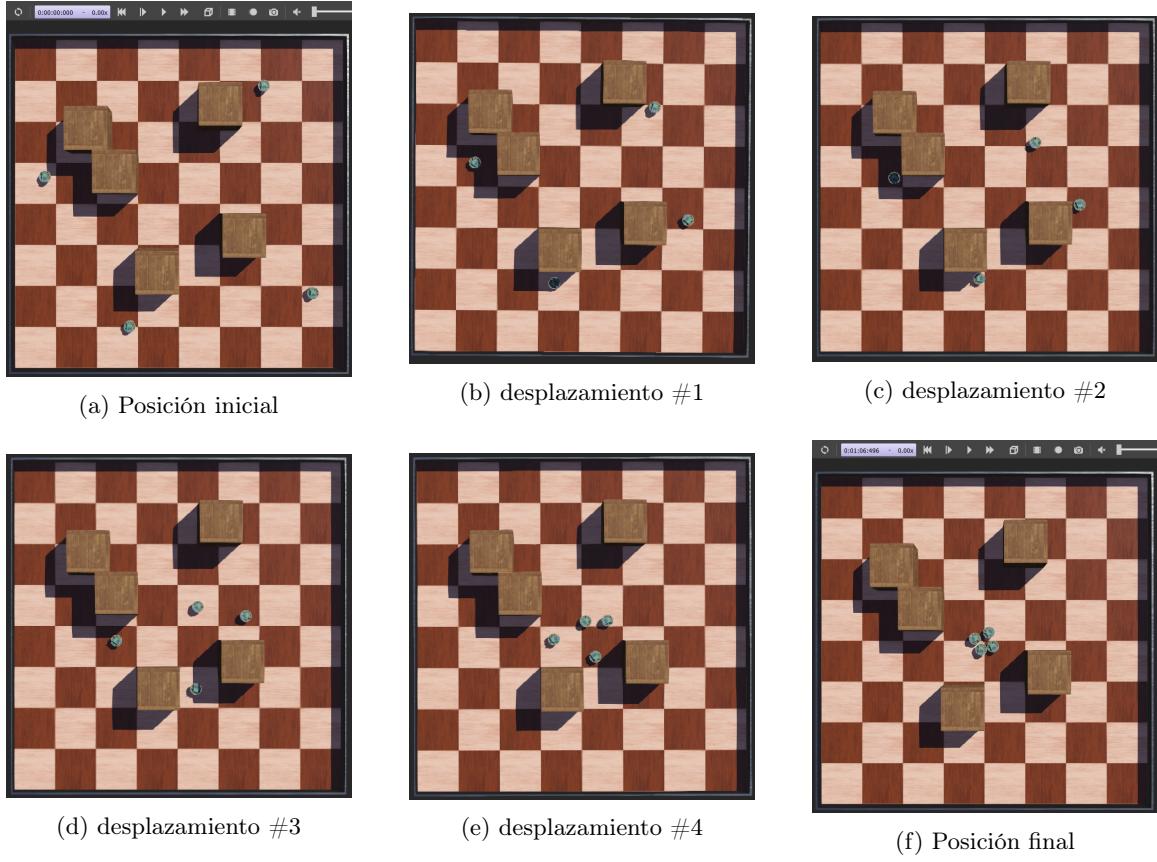


Figura 28: Trayectoria de los robots utilizando el algoritmo de braitenberg y algoritmo PSO

Como se puede observar en las Figura 28, el algoritmo PSO es capaz de converger al mínimo global siendo capaz de evadir los obstáculos dentro del entorno. El sistema es capaz de detectar cuando el obstáculo esta cerca y realiza los giros pertinentes para lograr evadir el obstáculo y dirigirse hacia el punto establecido por el algoritmo PSO. En el caso de las imágenes mostradas, se utiliza un controlador LQR debido a que es el controlador que obtuvo mejores resultados en lo que respecta a la velocidad de convergencia del algoritmo al igual que la forma en la cual converge.

# CAPÍTULO 10

---

## Conclusiones

---

- Se logró implementar un algoritmo capaz de navegar a través de terrenos desconocidos y siguiendo un comportamiento brindado por el algoritmo de optimización causando que el robot converja hacia el mínimo local de la función de costo.
- Se determinó que los simuladores con motores de física presentan un comportamiento más parecido a una aplicación física real. El sistema se comporta diferente al modelo idealizado dentro de las simulaciones de el *Swarm Robotics Toolbox*.
- Los parámetros obtenidos por el *PSO Tuner* generan una convergencia relativamente rápida hacia el mínimo local de la función de costo.
- Se determinó la viabilidad de la utilización de ROS para simulaciones de algoritmos de búsqueda de trayectorias como lo es el algoritmo de Dijkstra.

# CAPÍTULO 11

---

## Recomendaciones

---

- Se recomienda la utilización de un nodo supervisor capaz de indicarle a cada robot el punto al cual debe moverse y llevar un control de las trayectorias para evitar colisiones de los robots.
- Al momento de realizar las simulaciones dentro de estos entornos, tomar en consideración las restricciones que estos mismos presentan.
- Las mediciones realizadas por estos simuladores son estrictamente utilizando su propio sistema de coordenadas, por lo cual para una implementación física es necesario tomar en consideración estos ajustes.
- Los parámetros brindados por el *PSO Tuner* son idealizados por lo cual el resultado puede no ser el esperado en relación a los resultados que se obtienen en las simulaciones.

## CAPÍTULO 12

---

### Bibliografía

---

- [1] J. Kennedy y R. Eberhart, «Particle swarm optimization,» en *Proceedings of ICNN'95 - International Conference on Neural Networks*, vol. 4, 1995, págs. 1942-1948. DOI: 10.1109/ICNN.1995.488968.
- [2] E. Santizo, «Aprendizaje Reforzado y Aprendizaje Profundo en Aplicaciones de Robótica de Enjambre,» Tesis de licenciatura, Universidad del Valle de Guatemala, 2021.
- [3] M. Castillo, «Diseñar e implementar una red de comunicación inalámbrica para la experimentación en robótica de enjambre,» Tesis doct., 2019.
- [4] S. Ziadi, M. Njah y M. Chtourou, «PSO optimization of mobile robot trajectories in unknown environments,» *International Multi-Conference on Systems, Signals & Devices*, vol. 13, págs. 774-782, 2016.
- [5] A. Aguilera, «Algoritmo Modificado de Optimización de Enjambre de Partículas (MPSO),» Tesis de licenciatura, Universidad del Valle de Guatemala, 2019.
- [6] J. Cahueque, «Implementación de enjambre de robots en operaciones de búsqueda y rescate,» Tesis de licenciatura, Universidad del Valle de Guatemala, 2019.
- [7] D. Álvarez, E. Toro y G. Ramón, «Algoritmo de Optimización cumulo de partículas aplicado en la solución de problemas de empaquetamiento óptimo bidimensional con y sin rotación,» *Scientia et Technica*, págs. 10-16, 2009.
- [8] Z. Chi, G. Hai-bing, G. Liang y Z. Wan-guo, «Particle Swarm Optimization(PSO) Algorithm,» Tesis de mtría., Huazhong University of Science & Technology, China, 2010.
- [9] A. González, «Aplicaciones de técnicas de inteligencia artificial basadas en aprendizaje profundo (deep learning) al análisis y mejora de la eficiencia de procesos industriales,» Tesis de mtría., Universidad de Oviedo, España, feb. de 2018.
- [10] The MathWorks, Inc., *¿Qué es una red neuronal?* <https://la.mathworks.com/discovery/neural-network.html>, 2021.
- [11] E. Morales, «Aprendizaje por Refuerzo,» *Instituto Nacional de Astrofísica, Óptica y Electrónica*, págs. 3-12, 2011.

- [12] K. Lobos, «Aplicaciones de aprendizaje reforzado en robótica móvil,» Tesis de licenciatura, Universidad de chile, 2018.
- [13] N. Heess, J. Hunt, T. Lillicrap y D. Silver, «Memory-based control with recurrent neural networks,» *CoRR*, 2015.
- [14] S. Koenig y M. Likhachev, «Fast Replanning for Navigation in Unknown Terrain,» *IEEE Transactions On Robotics And Automation*, vol. 20, págs. 1-10, 2002.
- [15] Yujin y G. Xiaoqiu, «Optimal Route Planning of Parking Lot Based on Dijkstra Algorithm,» en *2017 International Conference on Robots Intelligent System (ICRIS)*, 2017, págs. 221-224. DOI: 10.1109/ICRIS.2017.82.
- [16] D. Fan y P. Shi, «Improvement of Dijkstra's algorithm and its application in route planning,» en *2010 Seventh International Conference on Fuzzy Systems and Knowledge Discovery*, vol. 4, 2010, págs. 1901-1904. DOI: 10.1109/FSKD.2010.5569452.
- [17] V. Braatenberg, *Vehicles: Experiments in Synthetic Psychology*. Londres: MIT Press, 1986.
- [18] A. Lorandi, G. Hermida, E. Durán y J. Hernández, «Controladores PID y Controladores Difusos,» *Revista de la Ingenieria Industrial*, vol. 5, págs. 2-6, 2011.
- [19] Á. Fernández, «Modelado y control en el espacio de estados,» *Universidad politécnica de valencia*, págs. 12-15, 2016.
- [20] S. Castaño, «Variables de Estado o Espacio de Estados,» *Control Automático Educación*, 2021.
- [21] G. Beauchamp y R. Batista, «Aplicación de Técnicas de Control Óptimo a una plataforma estacionaria cuatrimotor,» *Revista de Ingeniería Electrónica, Automática y comunicaciones*, vol. XXXVII, págs. 34-49, 2016.
- [22] V. Chalán, «Desarrollo de un controlador óptimo LQR utilizando herramientas IOT para un sistema de presión constante controlado remotamente,» Tesis de mtría., Universidad politécnica salesiana, Quito, Ecuador, 2020.
- [23] Stéphane Magnenat, *Photo of the e-puck mobile robot*, [https://en.wikibooks.org/wiki/Cyberbotics%27\\_Robot\\_Curriculum/E-puck\\_and\\_Webots](https://en.wikibooks.org/wiki/Cyberbotics%27_Robot_Curriculum/E-puck_and_Webots), 2008.
- [24] C. Cianci, X. Raemy, J. Pugh y A. Martinoli, «Communication in a swarm of miniature robots: The e-puck as an educational tool for swarm robotics,» *International Workshop on Swarm Robotics*, págs. 103-115, 2006.
- [25] A. Cubides, «Diseño e implementación de un sistema de interacción entre robots dirigidos por un usuario y objetos virtuales,» Tesis de licenciatura, Universidad Autónoma de occidente, 2016.
- [26] J. Valencia, A. Montoya y L. Rios, «Modelo Cinemático de un robot móvil tipo diferencial y navegación a partir de la estimación odométrica,» *Scientia et Technica*, vol. 41, págs. 191-196, 2009, ISSN: 0122-1701.
- [27] S. Surjanovic y D. Bingham, *Virtual Library of Simulation Experiments: Test Functions and Datasets*, Retrieved September 28, 2021, from <http://www.sfu.ca/~ssurjano>.
- [28] Cyberbotics Ltd, *Webots*, <https://cyberbotics.com>, 2021.
- [29] ——, *Webots*, <https://cyberbotics.com/doc/reference/nodes-and-functions>, 2021.

- [30] The VRML Consortium Incorporated., *The Virtual Reality Modeling Language*, <http://www.vrml.org/Specifications/VRML97/index.html>, 1997.
- [31] M. Quigley, B. Gerkey, K. Conley, J. Faust, T. Foote, J. Leibs, E. Berger, R. Wheeler y A. Ng, «ROS: an open-source Robot Operating System,» *Computer Science Department, University of Southern California*, págs. 1-6, 2009.
- [32] T. Foote, «tf: The transform library,» en *Technologies for Practical Robot Applications (TePRA), 2013 IEEE International Conference on*, ép. Open-Source Software workshop, abr. de 2013, págs. 1-6. DOI: 10.1109/TePRA.2013.6556373.
- [33] Open Robotics, *Nodes*, <http://wiki.ros.org/es/Nodes>, 2021.
- [34] Open Source, *Gazebo*, <http://gazebosim.org>, 2014.
- [35] C. Fairchild y D. T. L. Harman, *ROS Robotics By Example*. Packt, 2016, ISBN: 9781782175193.
- [36] R. Merino, «Creación del modelo URDF del robot Manfred,» Proyecto de fin de carrera, Universidad Carlos III de Madrid, 2020.
- [37] J. Chavarría y J. Fallas, «El algoritmo PSO aplicado al problema de particionamiento de datos cuantitativos,» *Matemática, Educación e Internet*, vol. 19, n.º 1, págs. 1-13, 2019, ISSN: 1659-0643.
- [38] Cyberbotics Ltd, *Webots*, <https://cyberbotics.com/doc/guide/epuck>, 2021.
- [39] S. Sánchez, «Implementación y experimentación de herramientas para el diseño y desarrollo de comportamientos en robots tipo Turtlebot,» Trabajo Fin de Grado, Escuela politécnica superior, 2019.

# CAPÍTULO 13

---

## Anexos

---

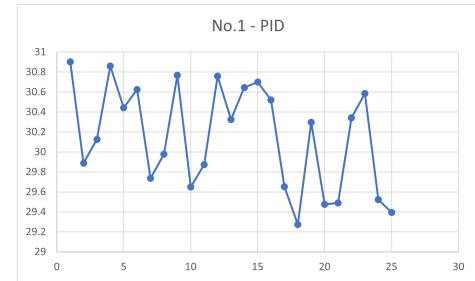
### 13.1. Simulaciones de Webots sin obstáculos

Cuadro 3: Promedio de tiempos de cada controlador por conjunto

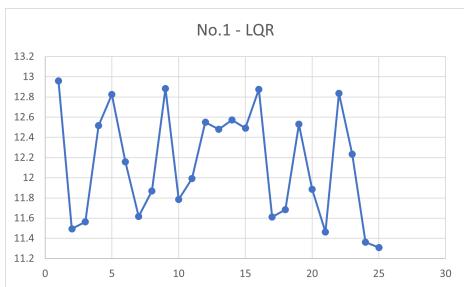
iteracion	PID (s)	LQR (s)	LQI (s)
<b>1</b>	30.24	12.16	34.496
<b>2</b>	29.38	11.488	35.264
<b>3</b>	28.42	9.76	35.712
<b>4</b>	29.1	10.144	34.08
<b>5</b>	30.12	9.76	35.168
<b>6</b>	28.23	10.368	34.816
<b>7</b>	28.61	9.824	33.024
<b>8</b>	28.42	9.92	33.536
<b>9</b>	28.64	10.944	34.72
<b>10</b>	29.472	10.304	37.516



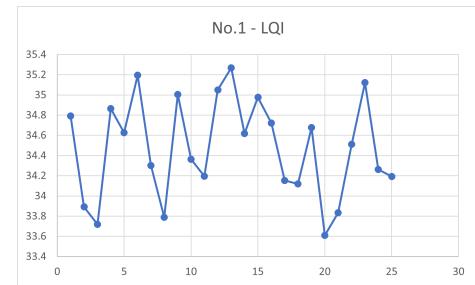
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

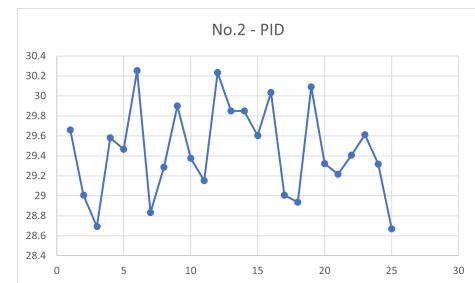


(d) Tiempos obtenidos con controlador LQI

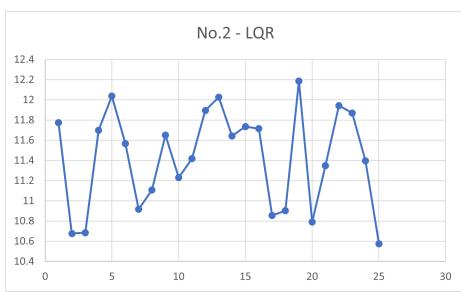
Figura 29: Primer Conjunto de simulaciones dentro de Webots



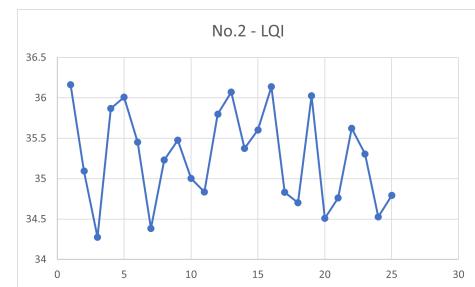
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

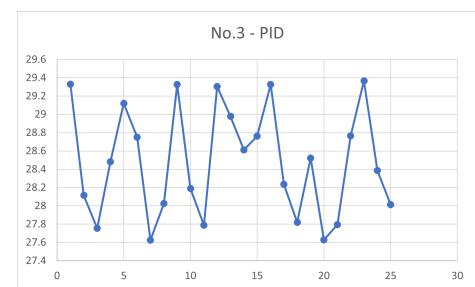


(d) Tiempos obtenidos con controlador LQI

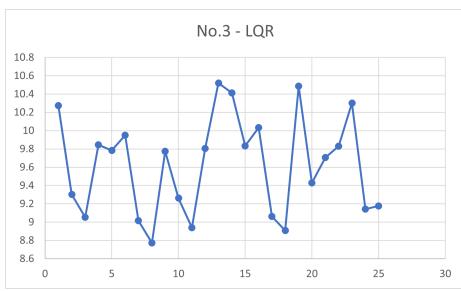
Figura 30: Segundo Conjunto de simulaciones dentro de Webots



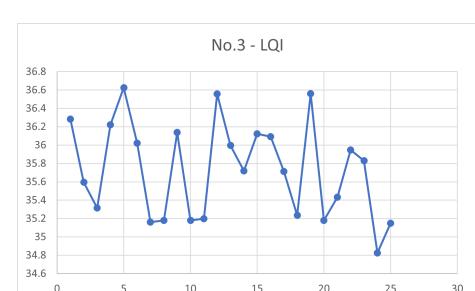
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

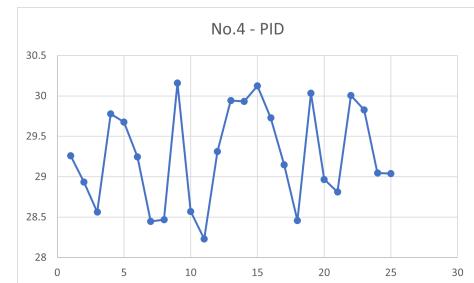


(d) Tiempos obtenidos con controlador LQI

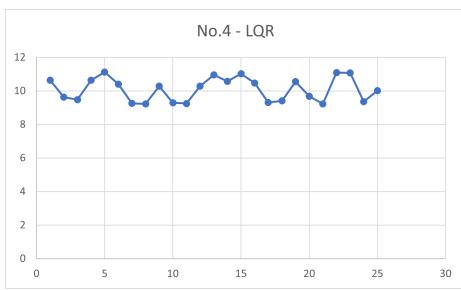
Figura 31: Tercer Conjunto de simulaciones dentro de Webots



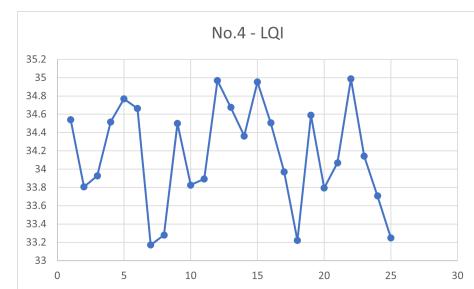
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

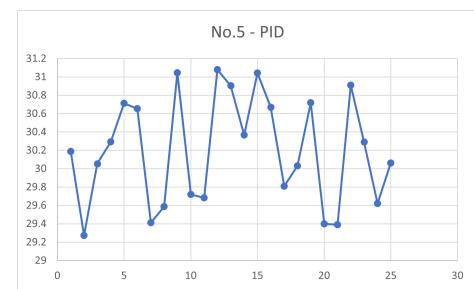


(d) Tiempos obtenidos con controlador LQI

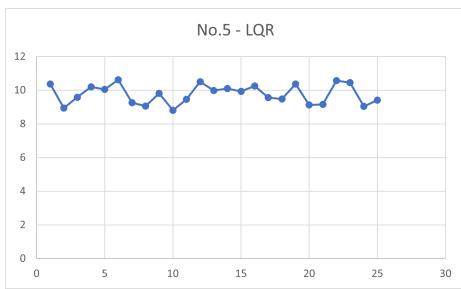
Figura 32: Cuarto Conjunto de simulaciones dentro de Webots



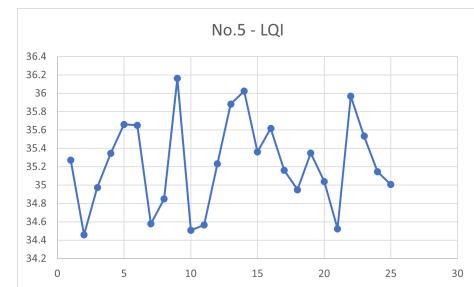
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

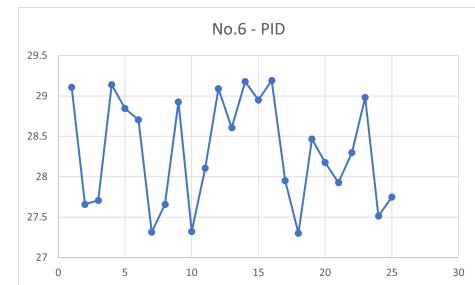


(d) Tiempos obtenidos con controlador LQI

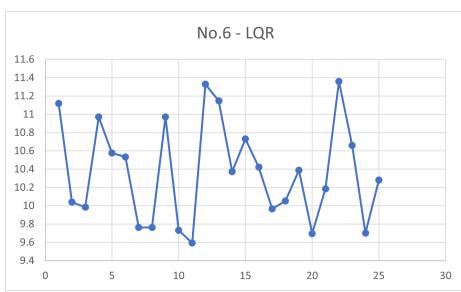
Figura 33: Quinto Conjunto de simulaciones dentro de Webots



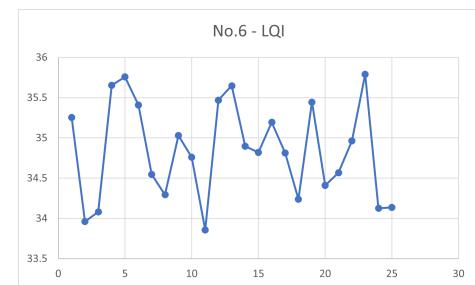
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

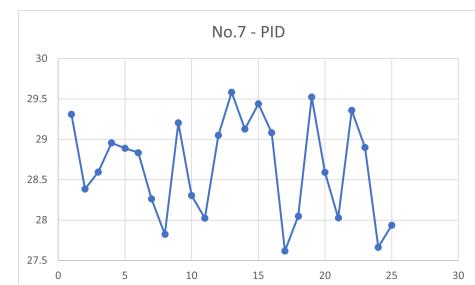


(d) Tiempos obtenidos con controlador LQI

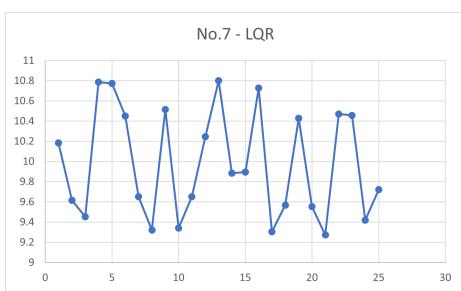
Figura 34: Sexto Conjunto de simulaciones dentro de Webots



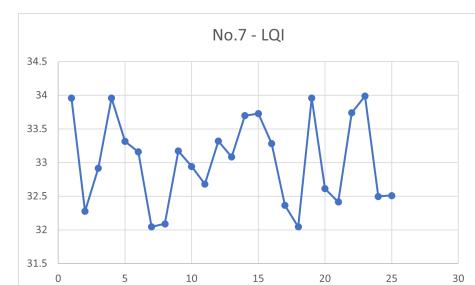
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID

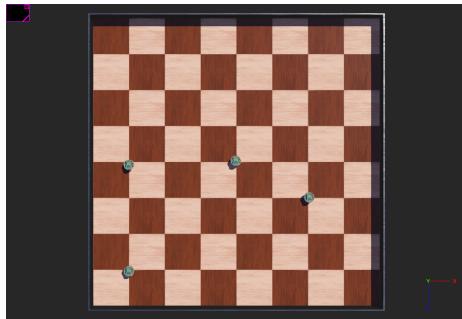


(c) Tiempos obtenidos con controlador LQR

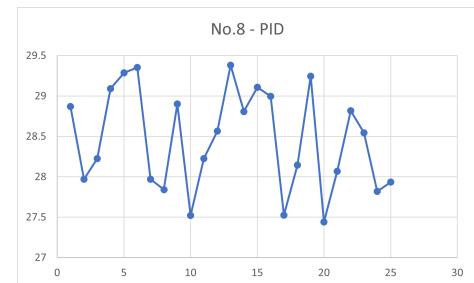


(d) Tiempos obtenidos con controlador LQI

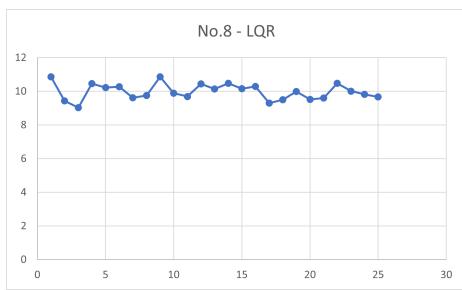
Figura 35: Séptimo Conjunto de simulaciones dentro de Webots



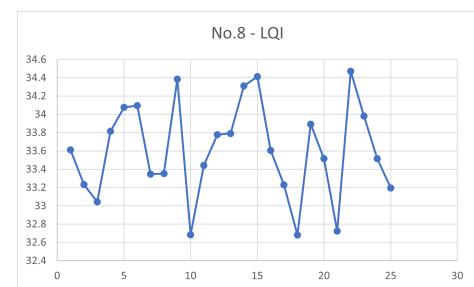
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

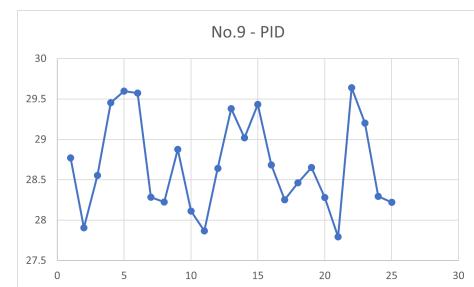


(d) Tiempos obtenidos con controlador LQI

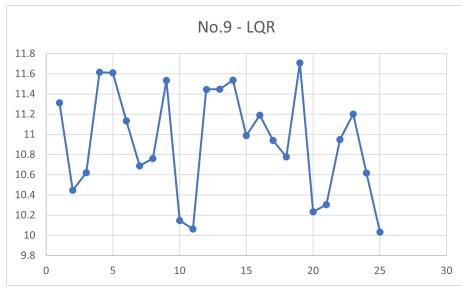
Figura 36: Octavo Conjunto de simulaciones dentro de Webots



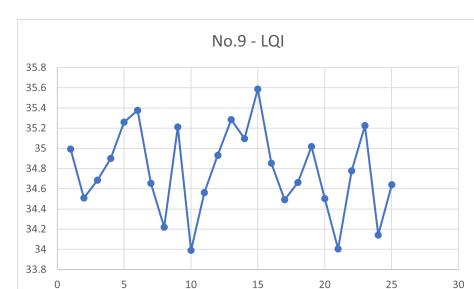
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR

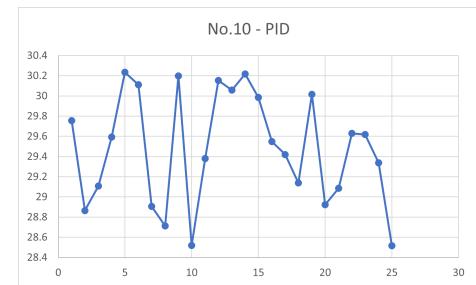


(d) Tiempos obtenidos con controlador LQI

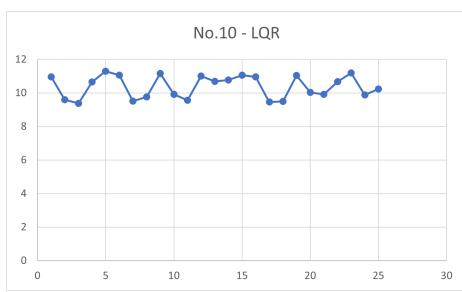
Figura 37: Noveno Conjunto de simulaciones dentro de Webots



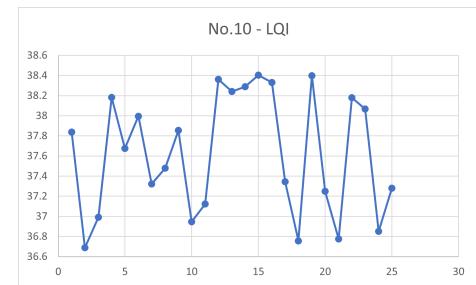
(a) Posición inicial



(b) Tiempos obtenidos con controlador PID



(c) Tiempos obtenidos con controlador LQR



(d) Tiempos obtenidos con controlador LQI

Figura 38: Décimo Conjunto de simulaciones dentro de Webots

### 13.2. Simulaciones con algoritmo D\* lite

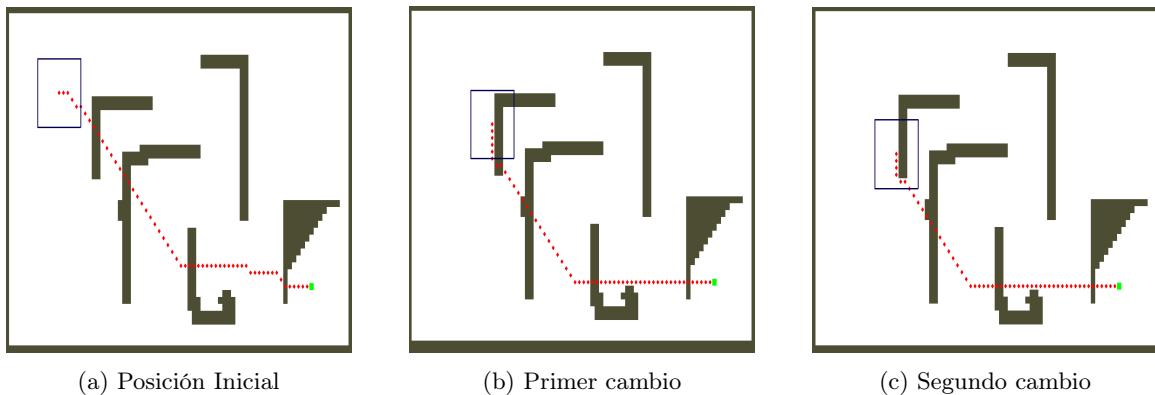


Figura 39: Primer conjunto de trayectorias generadas por el algoritmo D\* Lite

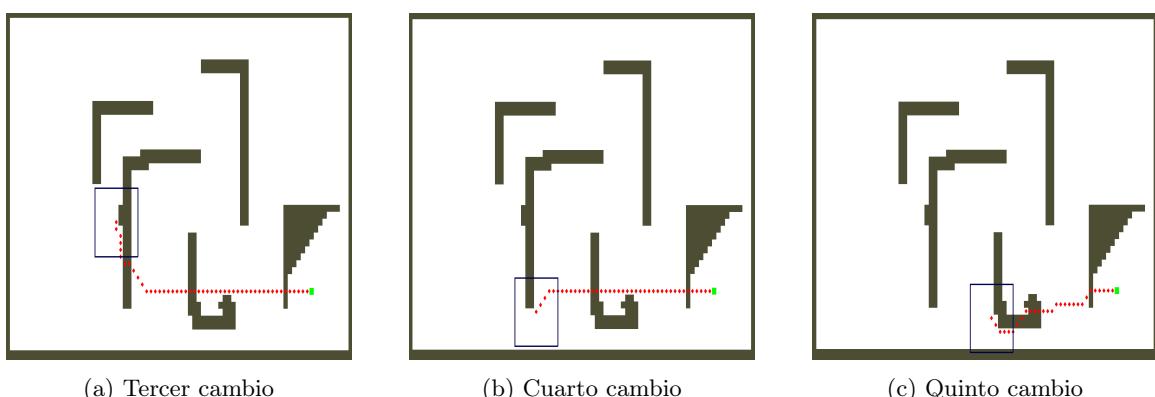


Figura 40: Segundo conjunto de trayectorias generadas por el algoritmo D\* Lite

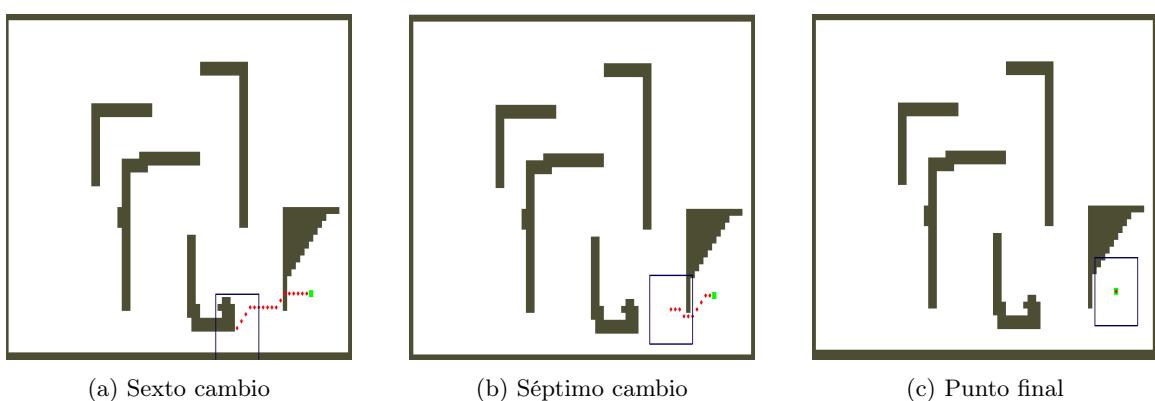


Figura 41: Tercer conjunto de trayectorias generadas por el algoritmo D\* Lite

